

张量烹饪书

托马斯·迪布达尔·阿勒2025

年2月9日

第1章

介绍

这是什么？这些页面是关于张量的指南，使用“张量图”的视觉语言。为了展示这种方法的广泛适用性，我尽量遵循了著名的《矩阵烹饪书》。因此，大部分内容都是关于张量及其相关事项的事实集合（如恒等式、近似、不等式、关系等）。你不会在这里找到太多不同于原书的内容，但希望这些图表能为你提供一种新的方式来理解和欣赏这些内容。

它还在进行中：《矩阵烹饪书》是一本长书，并非所有章节都适合添加图表。因此，我选择跳过某些部分并缩短其他部分。也许将来，我会或他人会进一步扩展内容。

例如，虽然我们已经涵盖了线性组合期望和高斯矩的所有结果，但跳过了关于一般多元分布的部分。此外，我还对材料进行了重新安排，以避免一开始就引入所有符号。

复矩阵和协方差张量图（或网络）目前在量子物理中最为常见，但这本书并非为物理学家而写。《矩阵烹饪书》是一本面向工程师的书籍，尤其适用于机器学习领域，因为在这个领域中复数的应用较少。没有复数，我们就不必担心复共轭的问题，这简化了转置过程，并且消除了对协变和逆变张量的需求。如果你是物理学家，你可能更需要一本关于张量分析的书。

张量图的符号性质使其非常适合符号计算。

张量图符号的优点：与其它符号相比，张量图符号具有许多优点：

各种操作，如迹、张量积或张量收缩，都可以简洁地表达，无需额外的符号。索引和张量的名称通常可以省略。这样做不仅节省时间，还简化了符号，尤其适用于那些主要用于求和的内部索引。由此产生的张量的顺序

一个复杂的收缩网络可以通过检查来确定：它就是未配对线的数量。例如，一个所有线都连接的张量网络，无论多么复杂，最终都会产生一个标量。

术语“张量”源自拉丁语单词“*tensio*”，意为“张力”或“拉伸”，这个词来源于动词“*tender*”，意为“拉伸”或“延伸”。19世纪中叶，威廉·罗万·汉密尔顿在其关于四元数的研究中首次引入了“张量”一词，当时它指的是四元数的大小。后来，格雷戈里奥·里奇-库尔巴斯特罗和图利奥·莱维-奇维塔在发展张量微积分时确立了“张量”的现代用法，这一框架将标量、向量和矩阵的概念推广到了更复杂的多维实体。[1,10]。

目录

1	介绍	1
1.1	Tensor图	7
1.2	复制张量	8
1.3	张量的和	9
1.4	转置	10
1.4.1	高阶	11
1.5	迹	11
1.5.1	高阶迹线	11
1.6	特征值	12
1.7	对称性与对称化	12
1.8	协变与逆变	13
1.9	练习	13
2	简单导数	14
2.1	矩阵、向量和标量形式的导数	14
2.1.1	一级	14
2.1.2	二级	15
2.1.3	高阶	16
2.2	痕量的导数	16
2.2.1	一级	16
2.2.2	二级	17
2.2.3	高阶	18
2.3	练习	18
3	克罗内克和向量运算符	20
3.1	压平	20
3.2	克罗内克积	21
3.3	向量运算符	22
3.4	克罗内克向量积	23
3.5	一般母体化	23
3.5.1	李雅普诺夫方程	23
3.5.2	总和汇总	24
3.6	哈达玛乘积	24
3.7	Khatri-Rao产品	25
3.8	Tracy-Singh产品	25

3.8.1	堆叠	25
3.9	导数	26
3.10	练习	26
4	功能	28
4.1	链式法则	29
4.1.1	黑森链规则	30
4.1.2	带有广播的链式规则	31
4.1.3	具有多个输入的功能	31
4.2	示例	31
4.2.1	已知的衍生品	31
4.2.2	伪线性形式	32
4.2.3	跟踪标识	32
4.2.4	泰勒	33
4.3	练习	33
5	统计学和概率论	37
5.1	力矩的定义	37
5.1.1	线性组合的期望值	37
5.1.2	线性形式	38
5.1.3	二次形式	38
5.1.4	立方形式	39
5.2	累积量	40
5.2.1	四次方程	41
5.3	加权标量变量	41
5.4	高斯矩	41
5.4.1	高斯分部积分	42
5.4.2	立方形式	42
5.4.3	四次形式的平均值	42
5.4.4	高斯混合	43
5.4.5	衍生品	44
5.5	练习	44
6	行列式和逆矩阵	45
6.1	行列式	45
6.2	反向	46
7	高级衍生品	47
7.1	向量范数的导数	47
7.1.1	二范数	47
7.2	矩阵范数的导数	48
7.3	结构化矩阵的导数	48
7.3.1	对称	48
7.3.2	对角线	48
7.3.3	托普利茨	48
7.4	行列式的导数	48
7.5	一般表格	48
7.6	线性形式	48

7.7	方形表单	48
7.8	来自Stack Exchange	48
7.9	逆函数的导数	48
7.9.1	跟踪标识	48
7.10	特征值的导数	49
7.11	练习	49
8	特殊矩阵	50
8.0.1	块矩阵	50
8.0.2	离散傅立叶变换矩阵	50
8.0.3	快速克罗内克乘法	50
8.0.4	厄米特矩阵和斜厄米特矩阵	54
8.0.5	幂等矩阵	54
8.0.6	正交矩阵	54
8.0.7	正定矩阵和半定矩阵	54
8.0.8	单条目矩阵, The	54
8.0.9	对称、斜对称/反对称	54
8.0.10	托普利茨矩阵	54
8.0.11	单位、置换和移位	54
8.0.12	范德蒙矩阵	54
9	分解	55
9.1	高阶奇异值分解	55
9.2	等级分解	55
9.2.1	边框等级	55
9.3	快速矩阵乘法	55
10	机器学习应用	58
10.1	最小二乘法	58
10.2	交叉熵损失的Hessian矩阵	58
10.3	卷积神经网络	58
10.4	变压器/注意	58
10.5	Tensor草图	58
10.6	强化学习	58
11	矩阵算法	59
11.1	张量收缩顺序	59
11.1.1	算法	60
12	张量梯度	61
12.1	同构	61
12.1.1	在产品中	61
12.1.2	总计	62
12.1.3	正在评估	63
12.1.4	在变量中	63
12.1.5	在常量中	63
12.1.6	在函数中	64
12.1.7	在衍生品领域	64

目录	6
12.1.8 其他的	64
12.2 重命名	64
12.3 评价	64
12.3.1 乘积	65
12.4 简化规则	66
13 附录	69

1.1 Tensor图

张量图是一种简单的图形（或称为“网络”），其中节点代表变量（例如向量或矩阵），而边则表示收缩操作（如矩阵乘法或内积）。下表展示了如何使用张量图来表示一些基本运算：

$$\text{点积 } a \cdot b \text{ 等于 } \sum_i a_i \cdot b_i \quad \left[\begin{array}{c} \cdot \\ \cdot \\ \cdot \\ \cdot \end{array} \right] \quad = y$$

外层产品a和b的Y_{i, j}值由a_i与b_j相乘，依次类推，最终结果为Y。

$$\text{矩阵-向量 } A \cdot b \text{ 分量 } y_i \text{ 等于各元素 } A_{i, j} \text{ 与 } b_j \text{ 的乘积之和 } \sum_j \left[\begin{array}{ccc} \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \end{array} \right] \left[\begin{array}{c} \cdot \\ \cdot \\ \cdot \end{array} \right] = y$$

$$\text{矩阵-矩阵 } A \cdot B \quad Y_{i, k} = \sum_j A_{i, j} B_{j, k} \quad \left[\begin{array}{ccc} \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \end{array} \right] \left[\begin{array}{ccc} \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \end{array} \right] = Y$$

我们通常将向量和矩阵视为一阶和二阶张量。这里的‘阶’指的是它们在可视化中的维度数，例如，向量是一维数字列表，而矩阵则是二维数字网格。此外，张量图中表示变量的节点的‘阶’也决定了其节点的复杂程度。

当涉及到3阶及以上的张量时，图示法变得更加有趣。3阶张量可以表示为一个立方体或一系列矩阵。例如，我们可以将其表示为 $T \in \mathbb{R}^{n \times m \times k}$ ，其中 $T_i \in \mathbb{R}^{m \times k}$ 是一个矩阵， $i = 1$ 到 n 。当然，我们也可以沿着其他轴对 T 进行切片，因此 $T_{:, j} \in \mathbb{R}^{n \times k}$ 和 $T_{:, :, l} \in \mathbb{R}^{n \times m}$ 也是矩阵。

一个具有两个输出边的矩阵意味着可以有两种方式将向量乘以它：一种是在左侧，即 $x^T M$ ；另一种是在右侧，即 $M x$ 。在图示中，我们简写为 $x \text{---} M$ 和 $\text{---} M x$ 。一个三阶张量有三条边，因此我们可以用三种方式将其与向量相乘：

$$T \text{---} x \text{ 和 } x \text{---} T \text{ 和 } T \text{---} x$$

为了准确地说明每个符号的意义，我们应该给边贴上标签。

例如，我们会这样写 $T \text{---} x$ ，我需要指定矩阵 $\sum_i T_i x_i$ 。然而，通常情况下，边 x

问题的答案将从上下文中清楚地得出，这也是张量图记法比爱因斯坦求和记法更清晰的原因之一。

$$Y_{i, j} = \sum_{k, l, m, n, o} A_{i, k} B_{k, l} C_{l, m} D_{m, n} E_{n, o} \quad \Leftrightarrow \quad \begin{array}{c} i \\ \diagdown \\ Y \\ \diagup \\ j \end{array} = \begin{array}{c} i \\ \diagdown \\ A \\ k \\ \diagup \\ C \\ j \end{array} \begin{array}{c} l \\ \diagdown \\ B \\ l \\ \diagup \\ D \\ m \end{array} \begin{array}{c} o \\ \diagdown \\ E \\ n \\ \diagup \end{array}$$

张量图的核心原则是边收缩具有结合性，即可以按任意顺序收缩任何边。这一点可以从上述求和表示中看出，该表达式可以重新排列，以任意顺序对 k, l, m, n 进行求和。

不同收缩顺序的计算成本可能差异很大。遗憾的是，找到最优顺序在计算上并不容易。请参阅第11.1节，了解寻找最佳收缩顺序的算法及近似收缩方法。

请注意，张量图并不总是连通的。我们已经看到两个向量的外积可以表示为 $a \cdot b$ 。这从求和表示法来看是自然的：没有边就意味着没有求和。因此这里 $y_i, j = a_i b_j$ ，这正是外积 $y = a \cdot b$ 。

1.2 复制张量

一个特别重要的张量是“复制”张量，也被称为“对角线”、“克罗内克 δ ”或“蜘蛛”张量。最简单的形式是一个全1向量，我们将其表示为 $\circ$ 。那就是当 $i = 1$ 时，一般 n 阶张量在对角线上取1，在其他位置全为0。

$$\circ_{i,j,k,\dots} = \begin{cases} 1 & \text{if } i = j = k = \dots \\ 0 & \text{otherwise} \end{cases}$$

或者，用艾弗森式符号表示， $1 \circ i, j, k, \dots = [i = j = k = \dots]$ 。我们观察到二阶副本张量 $\circ \cdot \circ = I$ 即单位矩阵，因此我们可以从这样的图中直接移除它：

$$-A - \circ - B - = -A - B -$$

高阶的副本张量非常有用，因为它们可以让我们把简单的张量图转换成超图。一个简单的例子是，我们如何使用这个方法。例如对角矩阵 D_a ，其对角线上元素为1，其余位置均为0。我们可以将其表示为

$$D_a = \circ \cdot a$$

为什么？因为 $(D_a)_{i,j}$ 等于 $\varepsilon_k \circ_{i,j,k} = \varepsilon_k [i = j = k] a_k = [i = j] a_i$ 。同样地，哈达玛积 $(a \cdot b)_i = a_i b_i$ 也可以表示为

$$a \cdot b = a \cdot \circ \cdot b$$

现在，让我们看看为什么大家都喜欢使用‘复制张量操作’来证明恒等式 $D_a D_b = D_{a \cdot b}$ 。

$$D_a D_b = \circ \cdot a \cdot \circ \cdot b = \circ \cdot (a \cdot b) = D_{a \cdot b}$$

您可以使用求和表示法验证这一点。

通常情况下，任何由复制张量构成的连通子图都可以合并成一个单一的子图。有时我们甚至幸运地发现这种简化是可行的。

¹For a logical proposition P , we define $[P] = \begin{cases} 1 & \text{if } P \\ 0 & \text{otherwise} \end{cases}$.

这给我们留下了一个我们可以移除的单位矩阵：

$$S \text{ --- } \text{---} \text{---} T = S \text{ --- } T = S - T$$

唯一需要特别小心的情况是当生成的张量阶数为0时。具体取决于您如何定义阶数为0的副本张量，您可能没有身份，也可能没有 $\circ \circ = \circ$ 。

许多需要特殊符号表示的构造（如对角矩阵或哈达玛积）可以通过复制张量与标准向量符号统一。在《矩阵烹饪书》中，他们定义了一个四阶张量 J ，满足条件 $J_{i,j,k,l} = [i = k][j = l]$ ，我们将其表示为 $J = \circ \circ$ ，and satisfies, for example, $\frac{dX}{dX} J$ 。通过使用“张量积”，可以将 J 表示为 $I \otimes I$ 。需要注意的是，这里的 J 与四阶副本张量不同。 $\otimes$.

1.3 张量的和

张量的乘积可以表示任何线性函数，即对于任意两个张量 a 和 b ，存在一个函数 f ，使得 $f(a \times x, b \times y) = a \times b \cdot f(x, y)$ 。然而，并非所有张量操作都是线性的。即使是两个向量 x 和 y 的简单相加 $x + y$ ，也无法用简单的收缩图来表示。（请注意，这并不是线性的，因为 $a \times x + b \times y \neq ab(x + y)$ 。）

为了处理这个重要的操作，Penrose 建议简单地把两个图用加号连接起来，比如 $-x + y$ 。请注意，这本身是一个一阶张量，尽管看起来像是有两个自由边缘。如果想要将这个和与另一个张量相乘，可以使用括号，例如 $-M(-x + y)$ 。

在处理求和时，使用命名边有助于明确边的匹配方式。求和与张量积之间存在良好的互动关系，并遵循一种通用的分配律形式：

$$R \text{ --- } \left(\begin{matrix} i \\ k \end{matrix} \begin{matrix} T \\ M \end{matrix} \begin{matrix} k \\ j \end{matrix} + \begin{matrix} i \\ k \end{matrix} \begin{matrix} V \end{matrix} \begin{matrix} k \\ j \end{matrix} \right) = \begin{matrix} T \\ M \\ U \text{ --- } R \end{matrix} + \begin{matrix} R \\ V \\ U \end{matrix}$$

当需要将具有不同数量边或边名称不同的张量相加时，可以采用“广播”技术。例如，若要将矩阵 M 与向量相加，

x 。这到底是什么意思？如果我们想把 x 加到 M 的每一行，我们就可以这样写。 $\frac{i}{x} M + \frac{i}{j} x$.

这是因为 $\frac{i}{j} x$ 是 x 与全一向量的外积，这是一个每一行都相同的矩阵。同样地，如果我们想将 x 加到每一列中，

我们可以用这个矩阵 $\frac{i}{x}$.

请注意，在处理张量时，我们通常不会提及“行”或“列”，而是直接使用张量的“边”（有时也称为“轴”）。当使用命名边时，可以省略经典向量表示中的操作，例如“转置”。矩阵

X^T 就是将 X 的左右边缘互换位置后的结果。但如果边缘被命名，我们就不必再追踪‘边缘的具体位置’了。

1.4 转置

在经典矩阵符号中，转置会翻转矩阵的索引，因此

$$(A^T)_{ij} \text{ 等于 } A_{ji}.$$

在张量图符号中，根据是否需要考虑边的位置重要性，我们有两种选择。当边的位置重要时，通常将‘左边’设为第一个索引，‘右边’设为第二个索引。因此，转置操作需要翻转这些边：

$$(-A-)^T = \overline{\underbrace{A}} = -A^T-.$$

一些作者使用的一种有趣的符号是将张量 A 倒置，作为一种更简单的方法来翻转左右边缘。

在实际计算中，跟踪边的位置很容易出错。

将张量的“输出”命名更为稳健，而转置则用于重命名边：

$$({}^i A - {}^j)^T = {}^{i-j} A {}^{i-j}$$

重命名可以通过乘以单位矩阵来完成：

$$({}^i A - {}^j)({}^{j-o-k}) = {}^i A {}^{j-k},$$

但是我们必须小心，因为重叠的边名可能会导致乘法不满足结合律。例如。

$$[({}^i A - {}^j)({}^{j-o-k})]({}^{k-o-j}) = {}^i A - {}^j \neq ({}^i A - {}^j)[({}^{j-o-k})({}^{k-o-j})] = {}^i A - {}^j \circledast,$$

在哪里 $\circledast$ 等于矩阵的维度。在`tensorgrad`中，我们通过要求任何边名在任何乘积中最多出现两次来解决这个问题。

为了转录矩阵烹饪书，使用“重要位置”。

记号更方便。我们观察到以下恒等式：

$$\begin{aligned} (A^T)^T &= A & \overline{\overline{A}} &= -A- \\ (A+B)^T &\text{ 的转置等于 } A^T \text{ 与 } B^T \text{ 的乘积 } \overline{(-A- + -B-)} = \overline{-A-} + \overline{-B-} \end{aligned} \quad (4)$$

$$(AB)^T = B^T A^T \quad \overline{\overline{A-B}} = \overline{\overline{B}} \overline{\overline{A}} = -B-V- \quad (5)$$

1.4.1 高阶

可以将转置的概念推广到更高阶的张量。这需要将边划分为“输入”和“输出”边，或者更常见的是，“逆变”和“协变”边。更多相关内容请参见本章末尾的部分。

我们说矩阵是对称的，如果 A^T 等于 A 。对于高阶张量，存在多种方式可以实现对称性。更多相关内容请参见第1.7节。

1.5 迹

方阵的“迹”定义为 $\text{Tr}(A) = \sum_i A_{ii}$ ， i 。在张量图表示法中，这对应于一条自边： A 。

《矩阵烹饪书》列出了使用迹的一些恒等式。让我们用张量图来重现这些恒等式：

$$\sum_{i=1}^n A_{ii} = \text{Tr}(A) = \text{Tr}(AI) \quad \text{A} = \text{A} \circ \text{I} \quad (11)$$

$$\text{Tr}(A) = \text{Tr}(A^T) \quad \text{A} = \text{V} \quad (13)$$

$$\text{Tr}(AB) = \text{Tr}(BA) \quad \text{A-B} = \text{A}^T = \text{B-A} \quad (14)$$

$$\text{Tr}(A+B) = \text{Tr}(A) + \text{Tr}(B) \quad \text{(-A- + -B-)} = \text{A} + \text{B} \quad (15)$$

$$\begin{aligned} \text{Tr}(ABC) &= \text{Tr}(BCA) & \text{A-B-C} &= \text{B-C-A} \\ &= \text{Tr}(CAB) & &= \text{C-A-B} \end{aligned} \quad (16)$$

$$\begin{aligned} a^T a &= \text{Tr}(aa^T) & a-a &= \text{Tr}(-a \ a-) \\ & & &= \text{a} \ a \end{aligned} \quad (17)$$

1.5.1 高阶迹线

对于更高阶的张量，我们依然将迹定义为对角元素的总和。也就是说，对于 n 阶张量 A ，其迹就是与 n 阶复制品张量相乘的结果：

$$\text{Tr}(\overset{|}{T}) = \text{T} \circ \text{T}.$$

在量子力学中，通常会使用“部分迹”，我们可以用索引符号来定义它：

$$\text{Tr}_{i,j}(\overset{|}{T}_{\underset{i}{\downarrow} \underset{j}{\downarrow}}) = \overset{|}{T}_{\underset{\circlearrowleft}{\downarrow}}.$$

当然，使用张量图时，我们也可以在不指定指标的情况下使用部分迹。我们甚至不必考虑所使用的收缩是否为迹。

1.6 特征值

特征值和特征向量是线性代数中的基本概念，在张量网络理论中有着重要的应用。在张量图表示法中，我们可以以直观的方式展示这些概念。

对于矩阵A，如果存在一个非零向量v和一个标量 λ ，使得 $Av = \lambda v$ ，则称 λ 为A的特征值，而v是对应的特征向量。在张量图表示法中，其特征分解可以方便地表示为 $A = Q \Lambda Q^{-1}$ ，其中Q是一个由A的特征向量组成的矩阵， Λ 是一个对角矩阵，包含特征值。因此：

$$-A- = -Q-\underset{\lambda}{\circ}-Q^{-1}- \quad (1.1)$$

矩阵的迹等于其特征值之和。我们可以通过张量图来表示这一关系：

$$\text{Tr}(A) = \text{A} = \text{Q}-\underset{\lambda}{\circ}-\text{Q}^{-1} = \underset{\lambda}{\circ} = \underset{\lambda}{\circ} = \sum_i \lambda_i \quad (12)$$

1.7 对称性与对称化

张量的一个共同特性是其对称性。对于矩阵而言，对称性意味着 $A^T = A$ 。而对于张量，这意味着交换其索引不会改变其值。典型的例子包括协方差矩阵或海森矩阵，以及某些高阶统计矩，如第三或第四矩张量，也表现出对称性。有时这种对称性仅限于特定的群，但大多数情况下，它涉及所有边的排列。Copy Tensor是完全对称张量的一个简单示例。

有时，通过对张量的所有指标排列求和来实现其对称化会非常有用。我们用一条波浪线覆盖对称化的边来表示这一过程：

$$\text{Z} = \text{---} + \text{X}, \quad \text{Z} = \text{---} + \text{X} + \text{---} + \text{X} + \text{X} + \text{X}$$

例如，如果A是一个方阵，则 $A + A^T$ 等于 $\text{---} A \text{---} = A + A$ 。存在一个互补的概念——反对称化（或斜对称化），其中我们对所有带有适当符号的排列求和。例如，一个秩为2的斜对称矩阵A满足 $A_{ij} = -A_{ji}$ 。我们可以通过一条平坦的粗线来进行反对称化： $\text{---} A \text{---} = A - A$ 。在更高阶的情况下，每个项的符号由排列的奇偶性决定。

这两个张量都是幂等的，因为对称化一个对称张量不会产生影响：

$$\text{Z} = \text{Z}, \quad \text{Z} = \text{Z}$$

1.8 协变与逆变

在物理学中，经常需要在不同的坐标系之间进行转换。大多数这样的变换会以不同的方式改变矩阵的左右两侧，以及行向量和列向量。对于张量而言，这些概念被概括为协变性和逆变性。通过这些概念，我们能够追踪‘输入’和‘输出’向量。此外，我们还需要区分诸如单位矩阵等元素， $\otimes$ ， $\otimes$ 和 $\otimes$ 。

这种概念允许以‘代数’方式组合张量，通过将输入边连接到输出边，就像我们处理矩阵和向量一样。然而，对于更复杂的张量，我们需要知道要组合哪些边，索引符号更为有用。

在计算机科学和机器学习中，协方差和逆变的概念通常没有用处，因此我们不会在本书中使用它。

1.9 练习

练习1：给定矩阵序列 $A^1, A^2, \dots, A^N \in \mathbb{R}^{n \times n}$ ，以及向量 $v^1, v^2, \dots, v^N \in \mathbb{R}^n$ ，利用张量图示法绘制由这些向量构成的矩阵 $A^1 v^1, A^2 v^2, \dots, A^N v^N$ 。练习2。使用张量图表示两个矩阵的哈达玛积（逐元素乘法）。这与常规矩阵乘法有何不同？（我们将在3.6节中进一步探讨。）

练习3：用张量图表示矩阵 $A = U \Sigma V^T$ 的奇异值分解。这与特征分解图有何异同？如何将其推广到更高阶的张量？（在第9.1节中我们将进一步探讨这一主题。）

第2章

简单导数

张量的导数，即该张量各元素的导数集合。我们可以跟踪 $\frac{dT}{dU}$ by making a tensor of shape 形状(T) $\cup$ 形状(U)。例如，若T为三阶张量而U为二阶张量，则绘制 dT/dU 。

$$\frac{dT}{dU} = \text{Diagram: A circle with a dot on its upper right edge. Two lines extend from the dot: one pointing up and to the right, and another pointing down and to the right. The letter 'T' is inside the circle.$$

这种记法遵循彭罗斯的定义。圆圈上的黑点引出的两条额外线，使得导数成为五阶张量。导数阶数以这种方式增长，正是我们最初遇到张量的主要原因之一。

当边数不多时，我们将使用如下所示的简单内联符号：

$$\succ(T)$$

《矩阵烹饪书》中定义了一个单元素矩阵 J_i , $j \in \mathbb{R}^{n \times n}$, 其特性是除 (i, j) 位置外所有元素均为零，而该位置的值为1。或者我们也可以这样表示： $J_i, n, j_m = [i = n][j = m]$ 。

2.1 矩阵、向量和标量形式的导数

2.1.1 一级

以下的一阶导数显示了导数算子的基本线性特性。

$$\frac{\partial x^T a}{\partial x} = a \qquad (x - \overset{\bullet}{a}) = (\overset{\bullet}{x}) - a = -a \qquad (69)$$

$$\frac{\partial a^T x}{\partial x} = a \qquad (a - \overset{\bullet}{x}) = a - (\overset{\bullet}{x}) = a \supset = -a \qquad (69)$$

$$\frac{\partial a^T X b}{\partial X} = a b^T \qquad (a - X - \overset{\bullet}{b}) = a - (X) \overset{\bullet}{-} b = a \supset \supset b \qquad (70)$$

$$(-X-)^{\overset{i}{\bullet}\underset{j}{\bullet}} = \underset{i}{\cap}^{\underset{j}{\cup}} \quad (73)$$

$$\begin{aligned} (iX - A - \overset{\text{m}}{\underset{\text{n}}{\bullet}}) &= -(X) \overset{\text{m}}{\underset{\text{n}}{\bullet}} - A - \\ &= i \bigcup_{\supset}^{\text{m}} A - \end{aligned} \quad (74)$$

二阶导数由乘积法则得出：

The diagrammatic equation shows a propagator with a self-energy insertion (a loop with a dot) equal to the sum of the bare propagator and the propagator with a self-energy insertion. The diagrams are labeled with 'T' and 'U' on the internal lines.

请注意，此规则独立于T和U之间的边数而成立，即使没有边。

$$\begin{aligned} \frac{\partial}{\partial X_{i,j}} \sum_{k,l,m,n} X_{k,l} X_{m,n} &= (\sum_{k,l} X_{k,l})^2 \\ &= 2 \sum_{k,l} X_{k,l} \end{aligned} \quad \begin{aligned} \left(\begin{array}{c} \circ - X - \circ \\ \circ - X - \circ \end{array} \right)^{\overset{i}{\bullet} \underset{j}{\bullet}} &= \begin{array}{c} \circ - X - \circ \\ \circ - (X) - \circ \end{array} + \begin{array}{c} \circ - (X) - \circ \\ \circ - X - \circ \end{array} \\ &= 2 \begin{array}{c} \circ - X - \circ \\ \circ - \overset{i}{\bullet} / \underset{j}{\bullet} - \circ \end{array} \end{aligned} \quad (76)$$

$$\begin{aligned} \frac{\partial b^T X^T X c}{\partial X} &= X(bc^T + cb^T) \\ (b - X^T - X - c) \text{ with a slash on } c &= b - X^T - (X \text{ with a slash}) - c \quad (77) \\ &+ b - (X^T \text{ with a slash}) - X - c \\ &= b - X^T - \text{diagonal slash} - c \\ &+ b - \text{diagonal slash} - X - c \\ &= -X - (-bc' + -cb') \end{aligned}$$

$$\begin{aligned} \frac{\partial}{\partial X_{i,j}}(X^T B X)_{k,l} &= \delta_{l,j}(X^T B)_{k,i} \\ &+ \delta_{k,j}(B X)_{i,l} \end{aligned} \quad \begin{aligned} (\textcircled{\text{K}}_X^T - B - X_{\text{I}})_{\text{I}}^{\text{I}} &= \textcircled{\text{K}}_X^T - B - \frac{\text{I}}{\text{J}} \frac{\text{I}}{\text{J}} \\ &+ \textcircled{\text{K}}_{\text{I}}^{\text{J}} B - X_{\text{I}} \end{aligned} \quad (79)$$

$$\frac{\partial}{\partial X_{i,j}} X^T B X = X^T B J^{i,j} + J^{j,i} B X \quad (\text{same as above}) \quad (80)$$

$$\begin{aligned} \frac{\partial}{\partial x} x^T B x &= (B + B^T)x \\ (x - B - x) &= -B - x + x - B \quad (81) \\ &= (-B - + -B^T -) - x \\ &= x - \left(\begin{smallmatrix} j & B & i \\ i & B & i \end{smallmatrix} \right) \end{aligned}$$

假设W是对称的, 那么... (84) - (88)

2.1.3 高阶

像 X^n 这样的矩阵的整数次幂，通过写出乘积并使用乘积法则，处理起来非常简单。《矩阵烹饪书》中包含了一些我们可以用这种方法处理的导数。

$$\begin{aligned} \frac{\partial (X^n)_{kl}}{\partial X_{ij}} &= \sum_{r=0}^{n-1} (X^r J^{ij} X^{n-1-r})_{kl} & \text{---} (X - X - X - \dots - X) \text{---} & \quad (90) \\ &= \text{---} (X) \text{---} X - X - \dots - X \text{---} \\ &+ \dots \\ &+ \text{---} X - X - X - \dots - (X) \text{---} \\ &= \sum_{r=0}^{n-1} \text{---} X^r \text{---} X^{n-r-1} \text{---} \end{aligned}$$

$$\begin{aligned} \frac{\partial}{\partial X} \mathbf{a}^T X^n \mathbf{b} &= \sum_{r=0}^{n-1} (X^r)^T \mathbf{a} \mathbf{b}^T (X^{n-1-r})^T & (a - X - \dots - X - b) \text{---} & \quad (91) \\ &= \sum_{r=0}^{n-1} a - X^r \text{---} X^{n-r-1} - b \\ &= \sum_{r=0}^{n-1} -(X^r)^T - a - b - (X^{n-r-1})^T - \end{aligned}$$

2.2 痕量的衍生物

《矩阵烹饪书》中包含了许多迹的导数。这些导数在经典符号表示中显得优雅，因为迹是标量，因此导数属于低阶。

2.2.1 一级

$$\begin{aligned} \frac{\partial}{\partial X} \text{Tr}(X) &= I & (\text{---} X \text{---}) \text{---} &= (\text{---} X \text{---}) \text{---} & \quad (99) \\ &= \text{---} \text{---} \\ &= -o- \end{aligned}$$

$$\begin{aligned} \frac{\partial}{\partial X} \text{Tr}(XA) &= A^T & (\text{---} X - A \text{---}) \text{---} &= (\text{---} X \text{---}) \text{---} A \text{---} & \quad (100) \\ &= \text{---} \text{---} A \text{---} \\ &= \text{等于} \end{aligned}$$

$$\frac{\partial}{\partial X} \text{Tr}(AXB) = A^T B^T \quad \left(\overbrace{A-X-B} \right) \nearrow = \overbrace{A-(X \nearrow)B} \quad (101)$$

$$= A \nearrow \searrow B \equiv A^T \times B^T$$

继续到 (102-105)。最后一个例子使用了克罗内克积，我们可能需要先介绍这个概念。

2.2.2 二级

$$\frac{\partial}{\partial X} \text{Tr}(X^2) = 2X^T \quad \left(\overbrace{X-X} \right) \nearrow \quad (106)$$

$$= \overbrace{(X \nearrow)X} + \overbrace{X-(X \nearrow)} \\ = \overbrace{\nearrow X} + \overbrace{X \searrow} \\ = 2 \cdot X^T -$$

$$\frac{\partial}{\partial X} \text{Tr}(X^2 B) = (XB + BX)^T \quad \left(\overbrace{X-X-B} \right) \nearrow \quad (107)$$

$$= \overbrace{(X \nearrow)X-B} + \overbrace{X-(X \nearrow)-B} \\ = \overbrace{\nearrow X-B} + \overbrace{X \searrow \searrow B} = - \\ B^T - X^T - + -X^T - B^T -$$

$$\frac{\partial}{\partial X} \text{Tr}(X^T B X) = \frac{\partial}{\partial X} \text{Tr}(X X^T B) \quad \left(\overbrace{X^T-B-X} \right) \nearrow \quad (108, 109, 110)$$

$$= \frac{\partial}{\partial X} \text{Tr}(B X X^T) = \overbrace{(X^T \nearrow)B-X} + \overbrace{X^T-B-(X \nearrow)} \\ = (B + B^T)X = \overbrace{\nearrow B-X} + \overbrace{X^T-B \searrow} \\ = -B-X- + -B^T-X-$$

$$\frac{\partial}{\partial X} \text{Tr}(X B X^T) = \frac{\partial}{\partial X} \text{Tr}(X^T X B) \quad \left(\overbrace{X-B-X^T} \right) \nearrow \quad (111, 112, 113)$$

$$= \frac{\partial}{\partial X} \text{Tr}(B X^T X) = \overbrace{(X \nearrow)B-X^T} + \overbrace{X-B-(X^T \nearrow)} \\ = X(B^T + B) = \overbrace{\nearrow B-X^T} + \overbrace{X-B-} \\ = -X-B^T- + -X-B-$$

最后一个方程有点令人惊讶，因为我们可能会认为我们可以简单地代入

在前一个方程式中，将 X 代入 X^T ，并得出结论

$$(B + B^T)X = \frac{\partial}{\partial X} \text{Tr}(XBX^T) = \frac{\partial}{\partial X} \text{Tr}(X^T BX) = X(B^T + B).$$

然而，显然并非如此。这种替换仅适用于线性情况。

函数，而不是二次函数。In general it is the case that $\frac{\partial}{\partial X} f(X)^T \neq \frac{\partial}{\partial X} f(X^T)$.

2.2.3 高阶

$$\begin{aligned} \frac{\partial}{\partial X} \text{Tr}(X^n) &= n(X^{n-1})^T && \overbrace{(X - X - X - \dots - X)} \\ &= \sum_{r=0}^{n-1} \overbrace{X^r \rightarrow X^{n-r-1}} && (121) \\ &= n(X^T)^{n-1} \end{aligned}$$

$$\begin{aligned} \frac{\partial}{\partial X} \text{Tr}(AX^n) &= \sum_{r=0}^{n-1} (X^r A X^{n-1-r})^T && \overbrace{(A - X - X - \dots - X)} \\ &= \sum_{r=0}^{n-1} \overbrace{A - X^r \rightarrow X^{n-r-1}} && (122) \\ &= \sum_{r=0}^{n-1} -(X^r)^T - A^T - (X^{n-r-1})^T - \end{aligned}$$

2.3 练习

练习4：求 $(x^T A x)^2$ 关于 x 的导数。

练习5. 求的二阶导数

$$x^T A^T x x^T A x$$

关于 x_0 。

练习6：求 $X^T A X$ 关于 X 的导数。

练习7. 求导数：

$$\frac{\partial}{\partial x} (Bx + b)^T C (Dx + d) = B^T C (Dx + d) + D^T C^T (Bx + b) \quad (78)$$

$$\frac{\partial}{\partial X} b^T X^T D X c = D^T X b c^T + D X c b^T \quad (82)$$

$$\frac{\partial}{\partial X} (Xb + c)^T D (Xb + c) = (D + D^T)(Xb + c)b^T \quad (83)$$

练习8：根据《矩阵手册》展示剩余的二阶迹导数。

$$\frac{\partial}{\partial X} \text{Tr}(AXBX) = A^T X^T B^T + B^T X^T A^T \quad (114)$$

$$\frac{\partial}{\partial X} \text{Tr}(X^T X) = \frac{\partial}{\partial X} \text{Tr}(XX^T) = 2X \quad (115)$$

$$\frac{\partial}{\partial X} \text{Tr}(B^T X^T CXB) = C^T XBB^T + CXBB^T \quad (116)$$

$$\frac{\partial}{\partial X} \text{Tr}[X^T BXC] = BXC + B^T XC^T \quad (117)$$

$$\frac{\partial}{\partial X} \text{Tr}(AXBX^T C) = A^T C^T XB^T + CAXB \quad (118)$$

$$\frac{\partial}{\partial X} \text{Tr}[(AXB + C)(AXB + C)^T] = 2A^T(AXB + C)B^T \quad (119)$$

练习9：根据《矩阵手册》展示四阶迹的导数：

$$\begin{aligned} \frac{\partial}{\partial X} \text{Tr}[B^T X^T CXX^T CXB] &= CXX^T CXBB^T \\ &\quad + C^T XBB^T X^T C^T X \\ &\quad + CXBB^T X^T CX \\ &\quad + C^T XX^T C^T XBB^T \end{aligned} \quad (123)$$

第3章

克罗内克矩阵和向量运算符

3.1 压平

扁平化是程序员常用的操作。在numpy中，我们可以通过`np.ones((2,3,4)).reshape(2,12)`将一个(2,3,4)的张量扁平化为(2,12)的矩阵。同样，在数学符号中，`vec(X)`通常用来表示将矩阵扁平化为向量的过程。

通常，这样做主要是为了应对张量的一般符号表示不佳的问题。因此，通过张量图，我们可以完全避免这种操作。然而，观察张量图如何使展平的许多属性更加透明，仍然非常有趣。

首先，我们注意到扁平化是一个线性操作，因此可以表示为一个简单的张量。我们将使用三角形来表示这一点：

$$\triangleright_{i,j,k} = \begin{array}{c} i \\ \diagup \\ j \end{array} \begin{array}{c} \diagdown \\ k \end{array} = [i + jn = k].$$

这里 n 表示第 i 条边的维度。请注意，我们使用双线来表示展平操作的输出。这只是语法上的选择，提醒我们输出是一对边的组合。

使用这种符号，我们可以写

$$\text{vec}(X)_k = \sum_{i,j} \triangleright_{i,j,k} X_{i,j} = X \begin{array}{c} \diagdown \\ k \end{array}.$$

的一些基本属性：

$$\begin{array}{c} \diagup \\ i \end{array} \begin{array}{c} \diagdown \\ j \end{array} = \begin{array}{c} \diagdown \\ j \end{array} \begin{array}{c} \diagup \\ i \end{array} \quad (3.1)$$

$$\begin{array}{c} \diagup \\ i \end{array} \begin{array}{c} \diagdown \\ j \end{array} \begin{array}{c} \diagup \\ k \end{array} \begin{array}{c} \diagdown \\ l \end{array} = \begin{array}{c} \diagup \\ i \end{array} \begin{array}{c} \diagdown \\ l \end{array} \begin{array}{c} \diagup \\ k \end{array} \begin{array}{c} \diagdown \\ j \end{array} \quad (3.2)$$

$$\begin{array}{c} \diagup \\ i \end{array} \begin{array}{c} \diagdown \\ j \end{array} \begin{array}{c} \diagup \\ k \end{array} \begin{array}{c} \diagdown \\ l \end{array} = \begin{array}{c} \diagup \\ i \end{array} \begin{array}{c} \diagdown \\ l \end{array} \begin{array}{c} \diagup \\ k \end{array} \begin{array}{c} \diagdown \\ j \end{array} \quad (3.3)$$

$$\begin{array}{c} \diagup \\ i \end{array} \begin{array}{c} \diagdown \\ j \end{array} \begin{array}{c} \diagup \\ k \end{array} \begin{array}{c} \diagdown \\ l \end{array} = \begin{array}{c} \diagup \\ i \end{array} \begin{array}{c} \diagdown \\ l \end{array} \begin{array}{c} \diagup \\ k \end{array} \begin{array}{c} \diagdown \\ j \end{array} \quad (3.4)$$

3.2 克罗内克积

$m \times n$ 矩阵A与 $r \times q$ 矩阵B的克罗内克积, 即 $mr \times nq$ 矩阵A⊗B, 定义为

$$A \otimes B = \begin{bmatrix} A_{1,1}B & A_{1,2}B & \cdots & A_{1,n}B \\ A_{2,1}B & A_{2,2}B & \cdots & A_{2,n}B \\ \vdots & \vdots & \ddots & \vdots \\ A_{m,1}B & A_{m,2}B & \cdots & A_{m,n}B \end{bmatrix}.$$

使用索引符号，我们也可以将其表示为 $(A?B) p (r-1)+v, q (s-1)+w = Ars Bvw$ ，但这种表达方式读起来相当困难。

在张量符号中，Kronecker积就是两个矩阵的外积。

两侧均被压平：A?B= $\longleftrightarrow$.

Kronecker乘积具有以下属性：

$$A \otimes (B + C) = A \otimes B + A \otimes C$$

$$\begin{aligned} \text{Diagram 1: } & \text{A vertex labeled 'A' with two incoming lines from the left and one outgoing line to the right. Below the vertex is the label '(B+C)'.} \\ \text{Diagram 2: } & \text{A vertex labeled 'A' with two incoming lines from the left and one outgoing line to the right. Below the vertex is the label 'B'.} \\ \text{Diagram 3: } & \text{A vertex labeled 'A' with two incoming lines from the left and one outgoing line to the right. Below the vertex is the label 'C'.} \end{aligned} \quad (506)$$

$$A \otimes (B \otimes C) = (A \otimes B) \otimes C$$


(508)

[illegible]

(A?B) 的转置等于AT与BT
的乘积。

$$\text{Diagram 1} = \text{Diagram 2} \quad (510)$$

$$(A \div B) \div (C \div D) \text{ 等于 } \frac{A - C}{B - D} \quad (511)$$

$$(A \otimes I)(I \otimes B) = A \otimes B$$


$$\text{Diagrammatic equation (511b): } \text{A} \otimes \text{B} = \text{A} \otimes \text{B}$$

矩阵A与B的转置相乘等于它们各自转置后的乘积

$$\begin{aligned} \text{Diagram 1} &= \text{Diagram 2} \\ &= \text{Diagram 3} \end{aligned} \quad (515)$$

回顾矩阵的特征分解 (1.1)，我们同样可以得到：

$$\begin{aligned} \text{特征值 (A?B) 等于特征值(A)乘以特征值(B)} &= \left\langle \left\langle \begin{array}{c} \lambda_1 \\ Q_1 - \circ - Q_1^{-1} \\ Q_2 - \circ - Q_2^{-1} \\ \lambda_2 \end{array} \right\rangle \right\rangle = \quad (519) \\ &= \left\langle \left\langle \begin{array}{c} \lambda_1 \\ Q_1 \\ Q_2 \end{array} \right\rangle \right\rangle \left\langle \left\langle \begin{array}{c} Q_1^{-1} \\ \circ \\ Q_2^{-1} \\ \lambda_2 \end{array} \right\rangle \right\rangle \\ &= \left\langle \left\langle \begin{array}{c} Q_1 \\ Q_2 \end{array} \right\rangle \right\rangle \left\langle \left\langle \begin{array}{c} Q_1^{-1} \\ \circ \\ Q_2^{-1} \\ \lambda_2 \end{array} \right\rangle \right\rangle \end{aligned}$$

其中最后一步是由于 (3.4)。

当我们考虑 $V = M$ 时，这一点就更容易理解了。表示张量，其中 V_i, j, i, j 等于 $M_{i, j}$ ，其他位置为0。因此，将 V 在两侧展平与 $\text{diag}(\text{vec}(M))$ 相同。

3.3 向量运算符

向矩阵 A 应用 vec 算子后，会将各列合并成一个向量。例如，对于一个 2×2 的矩阵，

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \quad \text{vec}(A) = \begin{bmatrix} A_{11} \\ A_{21} \\ A_{12} \\ A_{22} \end{bmatrix}$$

在本章开头，我们展示了如何通过展平张量来表示向量算子： $\text{vec}(X) = X_{\circ}$ 。《矩阵烹饪书》给出了 vec 算子的以下属性：

$$\text{向量 (A?B) 等于向量(X)的转置与矩阵 (A?B) 的乘积。} \quad X \begin{array}{c} \text{A} \\ \diagup \quad \diagdown \\ \text{B} \end{array} = X \begin{array}{c} \text{A} \\ \diagdown \quad \diagup \\ \text{B} \end{array} \quad (520)$$

$$\text{Tr (ATB) =vec(A)^Tvec} \quad A \begin{array}{c} \text{A} \\ \diagup \quad \diagdown \\ \text{B} \end{array} = A \begin{array}{c} \text{A} \\ \diagdown \quad \diagup \\ \text{B} \end{array} \quad (521)$$

$$(B), \text{vec (A + B) = vec} \quad (A+B) \begin{array}{c} \text{A} \\ \diagup \quad \diagdown \\ \text{B} \end{array} = A \begin{array}{c} \text{A} \\ \diagup \quad \diagdown \\ \text{B} \end{array} + B \begin{array}{c} \text{A} \\ \diagup \quad \diagdown \\ \text{B} \end{array} \quad (522)$$

$$(A) + \text{vec(B), vec (aA) =} \quad aA \begin{array}{c} \text{A} \\ \diagup \quad \diagdown \\ \text{B} \end{array} = a A \begin{array}{c} \text{A} \\ \diagup \quad \diagdown \\ \text{B} \end{array} \quad (523)$$

$$\text{with(A)} \quad a-X-B-X-c = X \begin{array}{c} \text{B} \\ \diagup \quad \diagdown \\ a \quad b \end{array} X \quad (524)$$

$$a^T X B X^T c = \text{vec}(X)^T (B^T c a^T) \text{vec}(X)$$

我们采用重写公式 $\text{vec}(AX + XB) = (I \otimes A + B \otimes I) \text{vec}(X)$ ，该公式源自张量图的整理过程。

$$\left(\begin{array}{c} -A-X- \\ + \quad -X-B- \end{array} \right) \text{---} = X \text{---} \overset{A}{\curvearrowright} \text{---} + X \text{---} \underset{B}{\curvearrowright} \text{---} = X \text{---} \left(\begin{array}{c} \text{---} \overset{A}{\curvearrowright} \text{---} \\ \text{---} \underset{B}{\curvearrowright} \text{---} \end{array} \right) \text{---}$$

之后，我们可以取正规矩阵的逆来得到

$$\text{向量}(X) \text{ 等于 } (I \otimes A + B \otimes I)^{-1} \text{ 乘以向量}(C)。 \quad (273)$$

3.5.2 总和汇总

这是对前一个方程的推广。

$$\sum_n A_n X B_n = C \quad (274)$$

$$\text{vec}(X) = \left(\sum_n B_n^T \otimes A_n \right)^{-1} \text{vec}(C) \quad (275)$$

3.6 哈达玛乘积

哈达玛积，也称为逐元素乘法，在《矩阵烹饪书》中未作介绍。然而，它是一个非常有用的运算，并且与克罗内克积有关联，具有一些有趣的性质。

我们定义两个 2×2 矩阵A和B的哈达玛积为

$$A \circ B = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \circ \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} & A_{12}B_{12} \\ A_{21}B_{21} & A_{22}B_{22} \end{bmatrix}.$$

在张量符号中，哈达玛积可以用两个秩为3的复制品张量表示：

$$A \circ B = - \circ \begin{array}{c} A \\ B \end{array} \circ -.$$

哈达玛积的一些性质是：

$$x^T (A \circ B) y = \text{tr} (A^T x B y)$$

$$x \text{---} \begin{array}{c} A \\ B \end{array} \text{---} y = \overbrace{A^T \text{---} x \text{---} B \text{---} y}^{\text{---}}$$

$$(A \otimes B) \circ (C \otimes D) = (A \circ C) \otimes (B \circ D)$$

$$\begin{array}{c} \text{---} \begin{array}{c} \text{---} \begin{array}{c} A \\ B \end{array} \text{---} \\ \text{---} \begin{array}{c} C \\ D \end{array} \text{---} \end{array} \text{---} = \text{---} \begin{array}{c} \begin{array}{c} A \\ B \end{array} \\ \begin{array}{c} C \\ D \end{array} \end{array} \text{---} \end{array}$$

第一个方程只是对张量图进行简单的调整。第二个方程则直接从(3.3)推导而来。或者，只需观察双线即可发现，A和C都使用了双线的“上部”，而B和D则使用了下部。

3.7 Khatri-Rao产品

也被称为列Kronecker积、行Kronecker积或“分叉积”。我们分别用符号*和?表示列Kronecker积和行Kronecker积。

$$A * B = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} * \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} & A_{12}B_{12} \\ A_{11}B_{21} & A_{12}B_{21} \\ A_{21}B_{11} & A_{21}B_{12} \\ A_{21}B_{21} & A_{22}B_{21} \end{bmatrix}$$

$$A \bullet B = \dots = \begin{bmatrix} A_{11}B_{11} & A_{12}B_{12} & A_{21}B_{11} & A_{21}B_{12} \\ A_{21}B_{21} & A_{22}B_{21} & A_{21}B_{22} & A_{22}B_{22} \end{bmatrix}$$

在张量图中，这些乘积简单地对应于将乘积的一侧展平，并在另一侧使用一个副本张量：

$$A * B = \begin{array}{c} A \\ \diagdown \quad \diagup \\ \text{---} \circ \text{---} B \end{array}$$

$$A \bullet B = \begin{array}{c} A \\ \diagdown \quad \diagup \\ \text{---} \circ \text{---} B \end{array}$$

显然，这两个矩阵在转置前是相同的。实际上， $(A * B)^T = B^T ? A^T$ ，而 $(A ? B)^T = B^T * A^T$ 。

存在多个“混合产品”标识：


$$(A \bullet B) (C ? D) = AC \bullet BD$$

$$(A x) ? (B y) = (A \bullet C) (x ? y)$$

$$\begin{array}{c} A \\ \diagdown \quad \diagup \\ \text{---} \circ \text{---} B \end{array} \begin{array}{c} C \\ \diagdown \quad \diagup \\ \text{---} \circ \text{---} D \end{array} = \begin{array}{c} A - C \\ \diagdown \quad \diagup \\ \text{---} \circ \text{---} B - D \end{array}$$

$$\begin{array}{c} A - x \\ \diagdown \quad \diagup \\ \text{---} \circ \text{---} B - y \end{array} = \begin{array}{c} A \\ \diagdown \quad \diagup \\ \text{---} \circ \text{---} B \end{array} \begin{array}{c} x \\ \diagdown \quad \diagup \\ \text{---} \circ \text{---} y \end{array}$$

3.8 Tracy-Singh产品



全部

3.8.1 堆叠

可作为Kronecker部分的一部分

根据Josh的命题2.5, 对于任意域F, 若存在整数 d_1, d_2, d_3, d_4 以及矩阵 $X_1 \in F^{d_1 \times d_2}, X_2 \in F^{d_2 \times d_3}, X_3 \in F^{d_3 \times d_4}$ 和 $X_4 \in F^{d_4 \times d_1}$, 则满足以下条件:

$$X_1 \times X_2 + X_3 \times X_4 = (X_1 | X_3) \times \begin{pmatrix} X_2 \\ X_4 \end{pmatrix},$$

我们用‘|’来表示矩阵的连接。

通过张量图, 我们可以将沿新轴 i 的堆叠表示为

$$\text{stack}_i(X, Y) = \overset{e^{(0)} \text{---} i}{\text{---} X \text{---}} + \overset{e^{(1)} \text{---} i}{\text{---} Y \text{---}}$$

其中 $e_i(i) = 1$, 其他位置为0。

因此, 我们很容易得到这个恒等式。

$$(A | C) \begin{pmatrix} B \\ D \end{pmatrix} = \text{stack}_i(A, C) \text{stack}_i(B, D) \quad (3.11)$$

$$= \left(\overset{e^{(0)} \text{---} i}{\text{---} A \text{---}} + \overset{e^{(1)} \text{---} i}{\text{---} C \text{---}} \right) \left(\overset{e^{(0)} \text{---} i}{\text{---} B \text{---}} + \overset{e^{(1)} \text{---} i}{\text{---} D \text{---}} \right) \quad (3.12)$$

$$= \overset{e^{(0)} \text{---} i}{\text{---} A \text{---}} \text{---} \overset{e^{(0)} \text{---} i}{\text{---} B \text{---}} + \overset{e^{(1)} \text{---} i}{\text{---} C \text{---}} \text{---} \overset{e^{(1)} \text{---} i}{\text{---} D \text{---}} \quad (3.13)$$

$$= AB + CD \quad (3.14)$$

待办事项: 与直接和的概念相关, 这基本上是将+堆叠起来再进行展平。或者, 或许通过与 e_i 向量的哈达玛积来处理会更合适。另外请注意, 这正是量子计算领域所说的‘控制’。

此外, 还有一系列属性, 例如 A 中 $(B \text{ 字段 } C) = A$ 中 B 字段 A 中 C 。

3.9 衍生品

3.10 练习

练习10: 设 $J = \text{Tr}[(I \text{ 中 } F)^\top A (I \text{ 中 } F) B]$, 其中 $F \in \mathbb{R}^n \times \mathbb{R}^n$, $A \in \mathbb{R}^{n^2 \times n^2}$, $B \in \mathbb{R}^{n^2 \times n^2}$ 。求 J 关于 F 的导数。

练习11: 考虑 $J = \|G - (B \text{ 中 } X)^2\|_F^2$, 其中 G 和 B 为矩阵, $\|\cdot\|_F$ 表示弗罗贝尼乌斯范数。求关于 X 的导数。

练习12: 证明方程[8]。

$$\text{vec}(A \text{ diag}(b) C) = ((C^T \otimes 1) \circ (1 \otimes A))b.$$

图中, $\text{diag}(b)$ 表示一个对角矩阵, 其对角线上是向量 b ; 1 是一个适当大小的全1向量。其中 A 代表向量与矩阵的克罗内克积, 定义为 $\text{vec}(A) \otimes b$, 也就是说, 你只需要在一边压平。

练习13: 设 a 和 b 为两个向量, D 和 X 为两个矩阵。求解关于 X 的最小化问题, 目标函数如下:

$$E = \|a - DXb\|_2^2.$$

练习14：利用图示证明 $\text{Tr}(AB) = \text{vec}(A)^T \text{vec}(B)$ ，其中1是适当大小的向量。

练习15. 求导数

$$\text{Tr}(G(A \otimes X))$$

关于X。

练习16。

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X} \otimes \mathbf{X}) = \frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}) \text{Tr}(\mathbf{X}) = 2 \text{Tr}(\mathbf{X}) \mathbf{I}$$

练习17. 求导数

$$\text{Tr}(G(A \otimes X))$$

关于X，其中G是一个 $\mathbb{R}^{n^2} \times \mathbb{R}^{n^2}$ 矩阵，而A和X是 $\mathbb{R}^n \times \mathbb{R}^n$ 矩阵。

将结果表示为 $\text{vec}(A)$ ，即G的重塑版本。

练习18. 验证以下恒等式：

$$\frac{d}{dx} \text{vec}(\text{diag}(x) A \text{diag}(x)) = \text{diag}(\text{vec}(A))(I \otimes x + x \otimes I).$$

提示：使用矩阵-向量恒等式 (3.5)。

练习19. 证明

$$\frac{\partial}{\partial x} x^T A (x \otimes x) = A(x \otimes x) + (x^T \otimes I + I \otimes x^T) A^T x$$

提示：使用矩阵-向量恒等式 (3.5)。

第4章

功能

在本章中，我们将探讨从一个张量到另一个张量的一般函数。虽然这些函数不如线性函数那样优雅，但它们在许多应用中非常重要，例如神经网络中的非线性特性。我们的主要目标是使向量链式法则直观易用，同时也会涉及泰勒级数、行列式等其他主题。

标准符号在处理向量上的函数时，当函数在某些维度上广播时，可能会显得相当模糊。例如，如果 $x \in \mathbb{R}^n$ 是一个向量，那么 $f(x)$ 是独立地应用于 x 的每个元素，还是作为整个向量的函数，这一点并不明确。通过张量图，我们通过明确显示 x 中哪些部分进入 f ，哪些不进入，来清晰地区分这一点。我们使用符号 $f \leftarrow x$ 当 f 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的函数时，记作 $n \times m$ 。若 f 是逐元素定义的，则表示为 $(f \leftarrow x) \in \mathbb{R}^n$ 。我们通常假设箭头边在普通边之前被收缩。如果需要其他形式，例如 $f(Mx)$ ，可以使用括号： $f \leftarrow (M \times x)$ 。如果再举一些例子可能会更有帮助：

$f : \mathbb{R}^n \rightarrow \mathbb{R}$	$f(x) \in \mathbb{R}$	$f \leftarrow x$	(标量函数)
$g : \mathbb{R}^n \rightarrow \mathbb{R}^m$	$g(x) \in \mathbb{R}^m$	$\overset{m}{\leftarrow} g \overset{n}{\leftarrow} x$	(矢量函数)
$h : \mathbb{R} \rightarrow \mathbb{R}$	$h(x) \in \mathbb{R}^n$	$h \leftarrow x \leftarrow n$	(元素级函数)
$u : \mathbb{R}^n \rightarrow \mathbb{R}^m, v \in \mathbb{R}^m$	$v^T u(x) \in \mathbb{R}$	$u \overset{m}{\leftarrow} v \overset{n}{\leftarrow} x$	向量乘以向量函数
$A : \mathbb{R}^n \rightarrow \mathbb{R}^{m \times n}, v \in \mathbb{R}^n$	$A(x) \in \mathbb{R}^m$	$\overset{m}{\leftarrow} A \overset{n}{\leftarrow} v$	向量乘矩阵函数
$f : \mathbb{R}^d \rightarrow \mathbb{R}, X \in \mathbb{R}^{b \times d}$	$f(X) \in \mathbb{R}^b$	$f \leftarrow X \leftarrow n$	(矢量函数，批处理)
$A : \mathbb{R}^{n \times m} \rightarrow \mathbb{R}, X \in \mathbb{R}^{n \times m}$	$A(X) \in \mathbb{R}$	$A \overset{n}{\leftarrow} X \overset{m}{\leftarrow}$	(矩阵输入函数)
$f : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^d, u \in \mathbb{R}^{b \times n}, v \in \mathbb{R}^{b \times m}$	$f(u, v) \in \mathbb{R}^{b \times d}$	$\overset{d}{\leftarrow} f \overset{n}{\leftarrow} u \overset{m}{\leftarrow} v \overset{b}{\leftarrow}$	(两个输入，批处理)

为了使概念更加具体，我们来看一些常见的函数：(1)行列式函数 $\det: \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$ 是一个标量函数，可以将其应用于一批数据。

通过行列式求矩阵的行列式 $\det_m \times b$ 的结果是一个向量 $\in \mathbb{R}^b$ 。(2)余弦相似度 $\text{cossim}: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ 是一个标量函数，我们可以通过 cossim 函数将其应用于两个向量。当 n 等于 v 时，结果为单一实数 $\in \mathbb{R}$ 。(3)若将逐元素幂函数 $\text{pow}_n: \mathbb{R} \rightarrow \mathbb{R}$ 应用于两个向量，则它们在哈达玛积下会简化：

$$\text{pow}_n \langle \dots u \rangle \circ \text{pow}_m \langle \dots u \rangle = \text{pow}_{n+m} \langle \dots u \rangle$$

以一个更高级的例子来说明，考虑softmax函数 $\text{softmax}(x)$ 。我们可以用初等函数来表示：

$$\text{softmax}(x) = \frac{\exp(x)}{\sum(\exp(x))} = \frac{\exp \langle \dots x \rangle}{\text{pow}_{-1} \langle \dots (\exp \langle \dots x \rangle) \rangle}$$

一开始看起来有点复杂，但让我们一步步来分解： $(\exp \langle \dots x \rangle) \in \mathbb{R}^n$ 表示逐元素指数函数。若将其与 $\dots$ 进行收缩操作，我们得到总和 $s = \sum_i \exp(x_i)$ 。最后，我们对 s 应用 pow_{-1} 并乘以指数函数，从而得到softmax函数。

如果输出张量与输入张量的广播边收缩，则可能出现一些令人困惑的情况。只要我们记得先收缩函数的边界，问题就能顺利解决。例如，对于函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 和矩阵 $x \in \mathbb{R}^m \times n$ ：


$$f \overbrace{\leftarrow n}^m x = \overbrace{f(x)}^m = \text{Tr}(f(x)).$$

4.1 链式法则

张量图的一个显著优点是链式法则的透明性。对于两个函数 $f: \mathbb{R}^m \rightarrow \mathbb{R}$ 和 $v: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ，复合函数 $f \circ v: \mathbb{R}^n \rightarrow \mathbb{R}$ 的图示方法非常简单，只需将 v 的输出直接代入 f 即可。

$$f \leftarrow v \leftarrow x$$

在传统符号体系中，链式法则表示为 $Jf \circ v(x) = Jf(v(x)) Jv(x)$ ，其中 $Jv(x)$ 代表 v 的雅可比矩阵， $Jf(v(x))$ 则是函数 f 在点 $v(x)$ 处的梯度。而在张量图示中，链式法则实际上就是一条链条！



这显然遵循了经典记忆法：“外函数的导数乘以内函数的导数”。我们唯一需要的改进是，‘外函数’通过取导数生成的新边与‘内函数’相连。


我们可以进一步简化 f 。对于函数 f ，其导数记作 f' 。例如，如果 f 是 $\cos(x)$ ，那么 f' 就是 $\sin(x)$ 。不过，我们也可以保留圈出的 f 作为导数的符号，这样更容易辨认。

4.1.1 黑森链规则


当我们考虑二阶导数时，情况变得更加有趣。使用标准符号，函数 $f \circ v$ 的海森矩阵为

$$H_{f \circ v}(x) = Dv(x)^T \cdot D^2 f(v(x)) \cdot Dv(x) + \sum_{k=1}^d \frac{\partial f}{\partial u_k}(v(x)) \frac{\partial^2 v_k}{\partial x \partial x^T}(x).$$

这个“黑森链规则”使用张量图更容易推导出来：




如果我们继续以这种方式扩展，我们会发现对于更多函数的链式法则存在一个简单的模式：



雅罗斯拉夫·布拉托夫广泛撰写了关于赫森链规则的文章，以及如何高效地在深度学习应用中评估这一规则。感兴趣的读者可以参考他关于该主题的博客文章。


4.1.2 带有广播的链式规则

当链式法则应用于具有广播特性的函数时，结果仍然遵循“外导数乘以内导数”的记忆规则，但“乘”的含义被扩展为广播边的哈达玛积。



4.1.3 具有多个输入的功能


如果函数 $f: \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}$ 具有两个输入，那么 $f(x, y)$ 的导数可以简单表示为 $\frac{\partial f}{\partial x} \partial x + \frac{\partial f}{\partial y} \partial y$, or in tensor diagram notation:



4.2 示例

4.2.1 已知的衍生品

两个可以扩展 f 的例子 • 已知导数：○



这里 $\text{inv}(X)$ 表示矩阵的逆函数，它将矩阵 X 转换为其逆矩阵 X^{-1} 。对于行列式而言，可以通过继续求导来发现其简单的模式。

$$\frac{\partial^k \det(X)}{\partial X^k} = \det(X) (X^{-1})^{\otimes k}.$$

4.2.2 伪线性形式

伪线性形式 $A(x)x$ 十分常见。所有像素自适应滤波器，如非局部均值、双边滤波等，以及变压器中的注意力机制，都可以用这种方式表示。根据Peyman Milanfar的观点，该函数的梯度非常重要，其形式值得记忆：

$$\begin{aligned} \text{D}[A(x)x] &= \text{D}[A(x)]x + A(x)\text{D}x \\ &= \int [A(x)]x + A(x)\text{D}x \\ &= \int A(x)\text{D}x + A(x) \\ &= (x^T \otimes I) \text{vec}[\text{D}[A(x)]] + A(x)\text{D}x \\ &= (x^T \otimes I) \text{D} \text{vec}[A(x)]\text{D}x + A(x)\text{D}x \\ &= [(x^T \otimes I) \text{D} \text{vec}[A(x)] + A(x)]\text{D}x \end{aligned}$$

当我们考虑Peyman Milanfar使用经典符号给出的以下推导时，我们可能会欣赏这种表达式的简洁性：

$$\begin{aligned} \text{d}[A(x)x] &= \text{d}[A(x)]x + A(x)\text{d}x \\ &= \int [A(x)]x + A(x)\text{d}x \\ &= \int A(x)\text{d}x + A(x) \\ &= (x^T \otimes I) \text{vec}[\text{d}[A(x)]] + A(x)\text{d}x \\ &= (x^T \otimes I) \text{D} \text{vec}[A(x)]\text{d}x + A(x)\text{d}x \\ &= [(x^T \otimes I) \text{D} \text{vec}[A(x)] + A(x)]\text{d}x \end{aligned}$$

最后意味着：


$$\frac{\partial A(x)x}{\partial x} = (x^T \otimes I) \frac{\partial}{\partial x} \text{vec}[A(x)] + A(x).$$

4.2.3 跟踪标识

《矩阵烹饪书》中有这样的公式：

$$\frac{\partial \text{Tr}(\sin(x))}{\partial x} = \cos(x)^T \quad (128)$$

如果我们尝试用张量图来推导这个，我们得到以下不同的结果，



这相当于 $\cos(x) \otimes I$ 。也就是说，除了对角线上的点外，其余位置均为零。

原因在于矩阵烹饪书实际上采用了‘函数应用于矩阵’这一概念的略微不同定义。如果函数 F 可以表示为幂级数形式，那么定义 $F(X)$ 的一种方法就是将其视为矩阵幂级数：

$$F(X) = \sum_{k=0}^{\infty} a_k X^k.$$

在这种情况下， $\text{Tr}(F(X))$ 的导数为 $f(X)^T$ ，其中 $f(x)$ 是 $f(x)$ 的标量导数，这与《矩阵手册》中的公式一致。

4.2.4 泰勒

对于一个n次可微的函数 $U: \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，我们可以写出其泰勒展开式：

$$\begin{array}{c} v \\ \uparrow \\ (x + \varepsilon) \end{array} \approx \begin{array}{c} v \\ \uparrow \\ x \end{array} + \begin{array}{c} \varepsilon \\ \bullet \\ \uparrow \\ x \end{array} + \frac{1}{2} \begin{array}{c} \varepsilon \\ \bullet \\ \bullet \\ \uparrow \\ x \end{array} + \frac{1}{6} \begin{array}{c} \varepsilon \\ \bullet \\ \bullet \\ \bullet \\ \uparrow \\ x \end{array} + \dots$$

用经典符号法写这个很混乱：

$$\begin{aligned} v(x + \varepsilon) &\approx v(x) + \left[\frac{\partial}{\partial x} v(x) \right] \varepsilon + \frac{1}{2} \left[\frac{\partial}{\partial x} \left[\frac{\partial}{\partial x} v(x) \right] \varepsilon \right] \varepsilon + \frac{1}{6} \left[\frac{\partial}{\partial x} \left[\frac{\partial}{\partial x} \left[\frac{\partial}{\partial x} v(x) \right] \varepsilon \right] \varepsilon \right] \varepsilon + \dots \\ &= v(x) + \left[\frac{\partial}{\partial x} v(x) \right] \varepsilon + \frac{1}{2} (I \otimes \varepsilon) \left[\frac{\partial \text{vec} \left[\frac{\partial v(x)}{\partial x} \right]}{\partial x} \right] \varepsilon + \frac{1}{6} (I \otimes \varepsilon \otimes \varepsilon) \left[\frac{\partial \text{vec} \left[\frac{\partial \text{vec} \left[\frac{\partial v(x)}{\partial x} \right]}{\partial x} \right]}{\partial x} \right] \varepsilon + \dots \end{aligned}$$

$\varepsilon + \dots$ 使用索引表示法即可：

$$v_i(x + \varepsilon) \approx v_i(x) + \sum_j \frac{\partial v_i(x)}{\partial x_j} \varepsilon_j + \frac{1}{2} \sum_{j,k} \frac{\partial^2 v_i(x)}{\partial x_j \partial x_k} \varepsilon_j \varepsilon_k + \frac{1}{6} \sum_{j,k,\ell} \frac{\partial^3 v_i(x)}{\partial x_j \partial x_k \partial x_\ell} \varepsilon_j \varepsilon_k \varepsilon_\ell$$

4.3 练习

练习20：绘制一个函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的张量图，该函数先应用逐元素非线性（例如exp），再对各分量求和。验证该图是否与softmax分母的传统公式相对应。练习21：表示两个函数的组合。

函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 和 $U: \mathbb{R}^m \rightarrow \mathbb{R}^n$ ，

首先，利用张量图。接着，借助图示链式法则，推导出函数 $f \circ U$ 关于参数 $\in \mathbb{R}^n$ 的导数表达式。

练习22：对于依赖于向量 α 的矩阵函数 $A(\alpha)$ ，请使用张量图来说明其导数。

$$\frac{\partial}{\partial x} [A(x)x],$$

并解释如何在图中实现产品规则。

练习23：将变分自编码器（VAE）的KL散度项表示为

$$KL(\mu, \sigma) = -\frac{1}{2} \left(1 + \log \sigma^2 - \mu^2 - \sigma^2 \right),$$

参数由以下给出

$$\mu = Wl + c \text{ 和 } \log \sigma^2 = Wl + c_0.$$

推导权重矩阵 W 关于梯度 $\nabla_W KL$ 的梯度。务必注意维度，并考虑逐元素操作。

练习24. 设定softmax函数 $s: \mathbb{R}^n \rightarrow \mathbb{R}^n$, 其定义方式为

$$s_i(z) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}, \quad i = 1, \dots, n.$$

证明 s 的雅可比矩阵由下式给出

$$\frac{\partial s_i}{\partial z_j} = s_i(\delta_{ij} - s_j),$$

其中 δ_{ij} 为克罗内克 δ 。

练习25. 假设 $x^{(1)}, \dots, x^{(n)} \in \mathbb{R}^d$ 是从多元正态分布 $N(\mu, \Sigma)$ 中独立抽取的样本。写出对数似然函数, 并推导出梯度 ∇_{μ} 和 ∇_{Σ} 。接着, 通过将这些梯度设为零, 证明最大似然估计量的计算方法。

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x^{(i)} \quad \text{and} \quad \hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (x^{(i)} - \hat{\mu})(x^{(i)} - \hat{\mu})^T.$$

练习26: 考虑一个高斯过程, 其协方差矩阵为 $K(\theta)$, 并定义对数边缘似然函数。

$$L(\theta) = -\frac{1}{2} \left(y^T K(\theta)^{-1} y + \log \det K(\theta) \right).$$

推导 L 关于 θ 的梯度, 证明这一点。

$$\frac{\partial L}{\partial \theta} = \frac{1}{2} \text{tr} \left(\left(K^{-1} y y^T K^{-1} - K^{-1} \right) \frac{\partial K}{\partial \theta} \right).$$

练习27. 在逻辑回归中, 设

$$p_i = \sigma(w^T x_i) \quad \text{with} \quad \sigma(z) = \frac{1}{1 + e^{-z}},$$

并考虑负对数似然

$$J(w) = - \sum_{i=1}^n \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right].$$

推导梯度 $\nabla_w J$ 和海森矩阵 $H = \nabla^2_w J$ 。特别地, 证明

$$\nabla_w J = \sum_{i=1}^n (p_i - y_i) x_i, \quad \text{and} \quad H = \sum_{i=1}^n p_i (1 - p_i) x_i x_i^T.$$

练习28: 设 $X \in \mathbb{R}^{n \times n}$ 为一个可逆矩阵, 证明其满足...

$$\frac{\partial \det(X)}{\partial X} = \det(X) (X^{-1})^T.$$

换句话说, 证明 $\det(X)$ 相对于 X 的梯度是 $\det(X)$ 乘以 X^{-1} 的转置。

练习29. 对于一个可逆矩阵 $X \in \mathbb{R}^n \times n$, 证明

$$\frac{\partial}{\partial X} \ln \det(X) = (X^{-1})^T.$$

简要讨论为什么这个结果在高斯似然等统计应用中是有用的。

练习30. 设 $A \in \mathbb{R}^n \times n$ 是一个可逆矩阵 (可能依赖于某个参数)。从单位矩阵 $I = A^{-1}A$ 出发, 对等式两边求导, 证明

$$d(A^{-1}) \text{ 等于 } -A^{-1} \text{ 乘以 } (dA) A^{-1}.$$

推导出偏导数的表达式 $\frac{\partial A^{-1}}{\partial A_{ij}}$.

练习31: 定义标量函数

$$f(A) = a^T A^{-1} b$$

其中 $a, b \in \mathbb{R}^n$ 为固定向量, $A \in \mathbb{R}^n \times n$ 是可逆矩阵。利用逆矩阵的微分结果, 证明

$$\frac{\partial f(A)}{\partial A} = -A^{-T} (ab^T) A^{-T}.$$

练习32: 设 $X \in \mathbb{R}^n \times n$ 是一个具有简单特征值 λ 及其对应的单位特征向量 v 的对称矩阵。证明 λ 关于 X 的导数可表示为

$$\nabla_X \lambda = v v^T.$$

此外, 讨论为什么当 λ 的重数大于1时, 这个结果不成立。

练习33: 对于对称矩阵 $A \in \mathbb{R}^n \times n$, 考虑其瑞利商。

$$R(x) = \frac{x^T A x}{x^T x}, \quad x \in \mathbb{R}^n \setminus \{0\}.$$

利用拉格朗日乘数法, 证明 $R(x)$ 的驻点值对应于矩阵 A 的特征值, 并且最大化 (最小化) 的点是与最大 (最小) 特征值对应的特征向量。

练习34. 设 $A \in \mathbb{R}^m \times m$ 和 $B \in \mathbb{R}^n \times n$ 为常数矩阵, $X \in \mathbb{R}^m \times n$ 为变量矩阵。证明

$$\frac{\partial}{\partial X} \text{Tr}(X^T A X B) = A X B^T + A^T X B.$$

(提示: 利用迹的循环性质重新排列项。)

练习35. (a) 证明对于常数矩阵 $A \in \mathbb{R}^m \times n$ 和变量 $X \in \mathbb{R}^m \times n$,

$$\frac{\partial}{\partial X} \text{Tr}(A^T X) = A.$$

(b) 更广泛地说, 对于常数矩阵 $A \in \mathbb{R}^p \times m$ 和 $B \in \mathbb{R}^n \times q$, 证明

$$\frac{\partial}{\partial X} \text{Tr}(A X B) = A^T B^T.$$

练习36：设向量 $s \in \mathbb{R}^n$ 和固定矩阵 $C \in \mathbb{R}^n \times n$ ，定义矩阵函数。

$$F(s) = \text{diag}(s) C \text{diag}(s),$$

其中 $\text{diag}(s)$ 表示由 s 的元素构成的对角矩阵。请用 s 、 ds 和 C 来表示微分 dF ，并由此推导出导数 $\nabla F(s)$ 的表达式。练习37：设 $A \in \mathbb{R}^p \times m$ ， $X \in \mathbb{R}^m \times n$ ， $B \in \mathbb{R}^n \times q$ 。证明恒等式。

$$\text{向量 } (AX \quad BT) \text{ 等于 } (B^T A) \text{ 乘以向量 } (X)。$$

讨论如何利用这种特性将某些矩阵导数问题转换为向量化形式。

练习38. 设

$$f(x) = x^T A x,$$

其中 $x \in \mathbb{R}^n$ 和 $A \in \mathbb{R}^n \times n$ 不一定是对称的。请证明这一点。

$$\nabla f(x) = (A + A^T) x.$$

接着，计算 $\text{Hessian} \nabla^2 f(x)$ ，并讨论当矩阵 A 是对称时会发生哪些简化。

Exercise 39. Consider the Frobenius norm $\|X\|_F = \sqrt{\text{Tr}(X^T X)}$, for $X \in \mathbb{R}^{m \times n}$.

显示

$$\nabla_X \|X\|_F = \frac{X}{\|X\|_F}$$

针对 $X \neq 0$.

练习40。设 $Y \in \mathbb{R}^n \times n$ 为一个对称矩阵，定义其最大特征值为 $\phi(Y)$ 。若该特征值的重数 k 大于1，则证明 $\phi(Y)$ 的导数存在多个可能值。特别地，需证明任何满足特定形式的矩阵均满足此结论。

$$G = \sum_{i=1}^k u_i v_i^T,$$

其中 $\{u_i\}_{i=1}^k$ 是对应最大特征值的特征空间的任意正交归一化基，是函数 $\phi(Y)$ 的有效次梯度。请解释在这种情况下定义唯一梯度时所面临的挑战。

统计学和概率论

设 $x \in \mathbb{R}^n$ 为一个随机变量。我们用 $m = E[x] \in \mathbb{R}^n$ 表示其期望值，并当这些量被定义时，协方差的计算公式为 $M = \text{Var}[x] = E[(x - m)(x - m)^T]$ 。在张量图中，我们将使用方括号表示：

该操作与收缩边的操作。

$$M_3 \begin{array}{c} \diagup \\ \diagdown \end{array} = \begin{bmatrix} (x \ominus m) - \\ (x \ominus m) - \\ (x \ominus m) - \end{bmatrix} \quad \text{and} \quad M_4 \begin{array}{c} \diagup \\ \diagdown \\ \diagup \\ \diagdown \end{array} = \begin{bmatrix} (x \ominus m) - \\ (x \ominus m) - \\ (x \ominus m) - \\ (x \ominus m) - \end{bmatrix}.$$

一般原理：“期望的线性”可以让你提取出图表中不涉及x的所有部分。

$$\boxed{\begin{array}{ccccc} A & & X & - & B & & C \\ | & \diagup & | & & & \diagup & | \\ X & - & D & - & X & - & E \end{array}} = \begin{array}{ccccc} A & & X & - & B & & C \\ | & \diagup & | & & & \diagup & | \\ X & - & D & - & X & - & E \end{array} = \begin{array}{c} A \quad \text{---} \quad B \quad \text{---} \quad C \\ \quad \quad \quad \diagdown \quad \quad \diagup \\ \quad \quad \quad D \quad \quad \quad \quad \quad \quad \\ \quad \quad \quad \diagup \quad \quad \diagdown \\ \quad \quad \quad X \quad \quad \quad X \end{array}$$

¹备注：这与上面刚刚介绍的符号不同。

我们甚至可以利用期望的线性特性，将期望值推入到一个无限张量的和中，如下所示的矩生成函数，它关联了所有MK张量：

$$\begin{aligned} E(e^{\langle x \ominus m, t \rangle}) &= \sum_{k=0}^{\infty} \frac{1}{k!} E[\langle x \ominus m, t \rangle^k] = E\left[\sum_{k=0}^{\infty} \frac{1}{k!} \langle (x \ominus m)^{\otimes k}, t^{\otimes k} \rangle\right] = \sum_{k=0}^{\infty} \frac{1}{k!} \langle M_k, t^{\otimes k} \rangle \\ &= 1 + \underset{m}{\overset{t}{|}} + \frac{1}{2} \underset{t}{\overset{t}{|}} M + \frac{1}{6} \underset{t}{\overset{t}{|}} M_3 + \frac{1}{24} \underset{t}{\overset{t}{|}} M_4 + \dots \end{aligned}$$

5.1.2 线性形式

《矩阵烹饪书》给出了以下简单的期望：

$$E[AXB + C] = AE[X]B + C \quad \begin{bmatrix} -A-X-B- \\ + -C- \end{bmatrix} = \begin{matrix} -A-[X]-B- \\ + -C- \end{matrix} \quad (312)$$

5.1.3 二次形式

我们通常更倾向于用简单的中心矩来表示期望，这可以通过提取均值来实现：

$$\begin{bmatrix} x- \\ x- \end{bmatrix} = \begin{bmatrix} (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} + \begin{matrix} m- \\ m- \end{matrix} = M \begin{matrix} \diagup \\ \diagdown \end{matrix} + \begin{matrix} m- \\ m- \end{matrix}$$

这使得处理《矩阵烹饪书》中的二次型变得简单：

$$\begin{aligned} \text{Var}[Ax] &= A \text{Var}[x] A^T & \begin{bmatrix} A-x \ominus [A-x] \\ A-x \ominus [A-x] \end{bmatrix} &= \begin{bmatrix} A-(x \ominus m) \\ A-(x \ominus m) \end{bmatrix} \\ & & &= \begin{matrix} A- \\ A- \end{matrix} \begin{bmatrix} (x \ominus m) \\ (x \ominus m) \end{bmatrix} \\ & & &= -A-M_2-A- \end{aligned} \quad (313)$$

$$\begin{aligned} E[x^T A x] &= \text{Tr}(AM) + m^T A m & m^T [x-A-x] &= \left(\begin{bmatrix} (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} + \begin{matrix} m- \\ m- \end{matrix} \right) \triangleright A \\ & & &= \begin{bmatrix} (x \ominus m) \\ (x \ominus m) \end{bmatrix} \begin{matrix} \diagup \\ \diagdown \end{matrix} A + \begin{matrix} m \\ m \end{matrix} \triangleright A \\ & & &= \overbrace{M-A} + m-A-m \end{aligned} \quad (318)$$

$$E[(Ax + a)(Bx + b)^T] = AMB^T + (Am + a)(Bm + b)^T \quad (320)$$

$$E[\mathbf{x}\mathbf{x}^T] = M + m m^T \quad (321)$$

$$E[\mathbf{x} \mathbf{a}^T \mathbf{x}] = (M + m m^T) \mathbf{a} \quad (322)$$

$$E[\mathbf{x} \mathbf{T} \mathbf{a} \mathbf{x}^T] = \mathbf{a}^T \times (M + m m^T) \quad (323)$$

$$E[(\mathbf{A}\mathbf{x}) (\mathbf{A}\mathbf{x})^T] = \mathbf{A} (M + m m^T) \mathbf{A}^T \quad (324)$$

$$E[(\mathbf{x} + \mathbf{a})(\mathbf{x} + \mathbf{a})^T] = M + (m + \mathbf{a})(m + \mathbf{a})^T \quad (325)$$

$$E[(\mathbf{A}\mathbf{x} + \mathbf{a})^T (\mathbf{B}\mathbf{x} + \mathbf{b})] = \text{Tr}(\mathbf{A}\mathbf{M}\mathbf{B}^T) + (\mathbf{A}\mathbf{m} + \mathbf{a})^T (\mathbf{B}\mathbf{m} + \mathbf{b}) \quad (326)$$


$$E[\mathbf{x}^T \mathbf{x}] = \text{Tr}(M) + m^T m \quad (327)$$

$$E[\mathbf{x} \mathbf{T} \mathbf{A} \mathbf{x}] = \text{Tr}(\mathbf{A}\mathbf{M}) + m^T \mathbf{A} \mathbf{m} \quad (328)$$

$$E[(\mathbf{A}\mathbf{x})^T (\mathbf{A}\mathbf{x})] = \text{Tr}(\mathbf{A}\mathbf{M}\mathbf{A}^T) + (\mathbf{A}\mathbf{m})^T (\mathbf{A}\mathbf{m}) \quad (329)$$

$$E[(\mathbf{x} + \mathbf{a})^T (\mathbf{x} + \mathbf{a})] = \text{Tr}(M) + (m + \mathbf{a})^T (m + \mathbf{a}) \quad (330)$$

5.1.4 立方形式



当 $\mathbf{x}$ 是一个具有均值向量 $\mathbf{m}$ 的随机向量时，使用中心矩展开原始三阶矩会更加方便：

$$\begin{aligned} \begin{bmatrix} x- \\ x- \\ x- \end{bmatrix} &= \begin{bmatrix} (x \ominus m)- \\ (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} + 3 \begin{bmatrix} (x \ominus m)- \\ m- \\ m- \end{bmatrix} + 3 \begin{bmatrix} m- \\ (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} + \begin{bmatrix} m- \\ m- \\ m- \end{bmatrix} \\ &= \underset{\substack{| \\ / \backslash}}{M_3} + 3 \begin{bmatrix} m- \\ -M- \\ m- \end{bmatrix} + \begin{bmatrix} m- \\ m- \\ m- \end{bmatrix} \end{aligned}$$

待办事项： $\mathbf{m}$ 、 $\mathbf{M}$ 项的边缘需要进行对称化处理。

不过这仍然有点混乱。请参见下面关于累积量的内容。

假设 $\mathbf{x}$ 是一个随机向量，其各分量相互独立，均值为 $\mathbf{m}$ ，协方差矩阵为 $\mathbf{M}$ ，中心矩 $\mathbf{v}$ 定义为 $E[(\mathbf{x} - \mathbf{m})^3]$ 。根据[7]的结论，

$$\begin{aligned} E[(\mathbf{A}\mathbf{x} + \mathbf{a})(\mathbf{B}\mathbf{x} + \mathbf{b})^T (\mathbf{C}\mathbf{x} + \mathbf{c})] &= \mathbf{A} \text{diag}(\mathbf{B}^T \mathbf{C}) \mathbf{v}_3 \\ &\quad + (\mathbf{A}\mathbf{m} + \mathbf{a})^T \text{Tr}(\mathbf{B}\mathbf{M}\mathbf{C}^T) \\ &\quad + \mathbf{A}\mathbf{M}\mathbf{C}^T (\mathbf{B}\mathbf{m} + \mathbf{b}) \\ &\quad + \mathbf{A}\mathbf{M}\mathbf{B}^T (\mathbf{C}\mathbf{m} + \mathbf{c}) \\ &\quad + (\mathbf{A}\mathbf{m} + \mathbf{a})^T (\mathbf{B}\mathbf{m} + \mathbf{b})^T (\mathbf{C}\mathbf{m} + \mathbf{c}) E[\mathbf{x}\mathbf{x}^T \mathbf{x}] \\ &= \mathbf{v}_3 \\ &\quad + 2\mathbf{M}\mathbf{m} \end{aligned}$$

$$+ (\text{Tr}(M) + m^T m)m$$

5.2 累积量

给定一个随机向量 $x \in \mathbb{R}^d$ ，其第 n 阶累积量张量 $K_n \in \mathbb{R}^d, \dots, d$ 的定义如下：

$$\log E(e^{\langle t, x \rangle}) = \sum_{n=1}^{\infty} \frac{1}{n!} \langle K_n, t^{\otimes n} \rangle = \frac{t}{K_1} + \frac{1}{2} \frac{t}{K_2} + \frac{1}{6} \frac{t}{K_3} + \dots$$

前几个累积量与中心矩类似：

$$K_1 = m, K_2 = M, K_3 = M_3, K_4 = M_4 - \frac{3}{M_2} M_2 M_2 - \frac{3}{M_2} M_2 M_2.$$

它们具有一个很好的特性（从定义中很容易看出），即对于独立随机变量，它们是可加的： $K_n(x+y) = K_n(x) + K_n(y)$ 。这一特性推广了标准性质，即独立随机变量之和的方差等于各方差之和。

我们可以用累积量来表示 x^n 的期望值：

$$\left[\begin{array}{c} x \ x \\ x \end{array} \right] = \frac{K_3}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_1}{K_2} + \frac{K_1}{K_2}.$$

通常，这个求和是对集合 $\{1, \dots, n\}$ 的所有划分进行的。

如果 x 的各个元素相互独立，那么累积量张量 K_2 和 $K_3, \dots$ 的非对角线部分将为零。这意味着，假设每个 x_i 的累积量分别为 $\kappa_1, \kappa_2, \kappa_3, \kappa_4 \in \mathbb{R}$ ，那么

$$\left[\begin{array}{c} x \ x \\ x \end{array} \right] = \kappa_4 \frac{K_4}{K_1} + \kappa_3 \kappa_1 \left(\frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} \right) + \kappa_2^2 \left(\frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} \right) + \kappa_2 \kappa_1^2 \left(\frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} \right) + \kappa_1^4 \frac{K_1}{K_1}$$

特别注意，当平均值 κ_1 为零时，仅有四个项得以保留。当 $n = 5$ 时，总共有 52 种划分方式，但若 κ_1 等于零，则仅有 11 种能够幸存：

$$\kappa_5 \frac{K_5}{K_1} + \kappa_3 \kappa_2 \left(\frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} + \frac{K_3}{K_1} \right)$$

当 x 服从高斯分布时，所有阶数为 3 及以上的累积量均为零。对于 $n = 6$ 的情况，总共有 203 种划分方式，但 $E[x^6]$ 的项数仅为 15 项。

$$\kappa_2^3 \left(\frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} + \frac{K_2}{K_1} \right).$$

²This is why $E[g^6] = 15$ for $g \sim N(0, 1)$.

5.2.1 四次方程

我们可以利用这一点来计算方差 $\text{Var}[A]$ 。假设 A 是对称矩阵：

$$\begin{aligned}
 \text{Var}[x^T A x] &= \boxed{\begin{array}{c} x \quad A \quad x \\ x \quad A \quad x \end{array}} - \boxed{\begin{array}{c} x \quad A \quad x \\ x \quad A \quad x \end{array}} \\
 &= \kappa_4 A \text{---} A + 4\kappa_3 \kappa_1 A \text{---} A - \\
 &\quad + 2\kappa_2^2 \text{---} A \text{---} + \kappa_2^2 \text{---} A \text{---} \\
 &\quad + 4\kappa_2 \kappa_1^2 \text{---} A - A - + 2\kappa_2 \kappa_1^2 \text{---} A \text{---} - A - \\
 &\quad + \kappa_1^4 \text{---} A - - A - \\
 &\quad - (\kappa_2 \text{---} A \text{---} + \kappa_1^2 \text{---} A - -)^2 \\
 &= 2\kappa_2^2 \text{---} A \text{---} + 4\kappa_2 \kappa_1^2 \text{---} A - A - \\
 &\quad + 4\kappa_3 \kappa_1 A \text{---} A - + \kappa_4 A \text{---} A
 \end{aligned}$$

《矩阵烹饪书》将其列为

$$\text{Var}[x^T A x] = 2\mu_2^2 \text{Tr}(A^2) + 4\mu_2 c^T A^2 c + 4\mu_3 c^T A a + (\mu_4 - 3\mu_2^2) a^T a \quad (319)$$

其中 $c = \mu$ 表示均值， $a = \text{diag}(A)$ 为矩阵 A 的对角线元素，而 $\mu_4 - 3\mu_2^2$ 则代表第四中心矩。

5.3 加权标量变量

设 $y = w^T x$ ， $m = E[y]$ ，则

$$E[y] = m = w^T \mu \quad (321)$$

$$E[(y - m)^2] = w^T M_2 w - w^T \mu^2 \quad (322)$$

$$E[(y - m)^3] = w^T M_3 w - 3w^T \mu M_2 w + 3w^T \mu^2 \mu - w^T \mu^3 \quad (323)$$

$$E[(y - m)^4] = w^T M_4 w - 4w^T \mu M_3 w + 6w^T \mu M_2 \mu^T w - 3w^T \mu^2 M_2 w + 3w^T \mu^2 \mu^T \mu - w^T \mu^4 \quad (324)$$

对于函数 $\sim N(0, 1)$ ，存在以下不等式：

$$E[y^n]^{1/n} \leq \sqrt{2/\pi} \|w\|_2.$$

5.4 高斯矩

对于高斯向量 $\sim N(m, M)$ ，其所有奇数中心矩均归零，例如 $M_3 = 0$ 等。甚至某些时刻也可以通过Isserlis定理计算。


例如：

$$\mathbb{E}[(x \ominus m)^{\otimes 4}] = M \otimes M + M \otimes M + \dots$$

(对不同索引的配对求和)。

5.4.1 高斯分部积分

如果 x 是一个具有高斯分布元素、零均值和特定协方差的张量，Stein引理可以给出一个非常通用的方程，适用于任何可微函数 f ：



结合第4章的张量链规则，这可以是一种评估许多困难期望的非常强大的方法。

$$E(xx^T) = \Sigma + mm^T \quad (377)$$

$$E[x^T A x] = \text{Tr}(A \Sigma) + m^T A m \quad (378)$$

$$\text{Var}(x^T A x) = \text{Tr}[A \Sigma (A + A^T) \Sigma] + \dots \quad (379) + m^T (A + A^T) \Sigma (A + A^T) m$$

$$E[(x - m')^T A (x - m')] = (m - m')^T A (m - m') + \text{Tr}(A \Sigma) \quad (380)$$

若 Σ 等于 $\sigma^2 I$ 且 A 是对称矩阵，则

$$\text{Var}(x^T A x) = 2\sigma^4 \text{Tr}(A^2) + 4\sigma^2 m^T A^2 m \quad (381)$$

假设 $x \sim N(0, \sigma^2 I)$ ，且 A 和 B 是对称的，那么

$$\text{Cov}(x^T A x, x^T B x) = 2\sigma^4 \text{Tr}(AB) \quad (382)$$

5.4.2 立方形式

假设 x 是一个随机向量，其各分量相互独立，均值为 m ，协方差矩阵为 M 。

$$E[xb^T xx^T] = mb^T (M + mm^T) + (M + mm^T)bm^T + b^T m (M - mm^T) \quad (383)$$

5.4.3 四次形式的平均值

$$E[xx^T xx^T] = 2(\Sigma + mm^T)^2 + m^T m (\Sigma - mm^T)$$

$$+ \text{Tr}(\Sigma)(\Sigma + mm^T)$$

$$E[\mathbf{x}\mathbf{x}^T\mathbf{A}\mathbf{x}\mathbf{x}^T] = (\Sigma + mm^T)(\mathbf{A} + \mathbf{A}^T)(\Sigma + mm^T) \\ + m^T\mathbf{A}m(\Sigma - mm^T) + \text{Tr}[\mathbf{A}\Sigma](\Sigma + mm^T)$$

$$E[\mathbf{x}^T\mathbf{x}\mathbf{x}^T\mathbf{x}] = 2\text{Tr}(\Sigma^2) + 4m^T\Sigma m + (\text{Tr}(\Sigma) + m^Tm)^2$$

$$E[\mathbf{x}^T\mathbf{A}\mathbf{x}\mathbf{x}^T\mathbf{B}\mathbf{x}] = \text{Tr}[\mathbf{A}\Sigma(\mathbf{B} + \mathbf{B}^T)\Sigma] + m^T(\mathbf{A} + \mathbf{A}^T)\Sigma(\mathbf{B} + \mathbf{B}^T)m \\ + (\text{Tr}(\mathbf{A}\Sigma) + m^T\mathbf{A}m)(\text{Tr}(\mathbf{B}\Sigma) + m^T\mathbf{B}m)$$

$$E[\mathbf{a}^T\mathbf{x}\mathbf{b}^T\mathbf{x}\mathbf{c}^T\mathbf{d}^T\mathbf{x}] = (\mathbf{a}^T(\Sigma + mm^T)\mathbf{b})(\mathbf{c}^T(\Sigma + mm^T)\mathbf{d}) \\ + (\mathbf{a}^T(\Sigma + mm^T)\mathbf{c})(\mathbf{b}^T(\Sigma + mm^T)\mathbf{d}) \\ + (\mathbf{a}^T(\Sigma + mm^T)\mathbf{d})(\mathbf{b}^T(\Sigma + mm^T)\mathbf{c}) - 2\mathbf{a}^T\mathbf{m}\mathbf{b}^T\mathbf{m}\mathbf{c}^T\mathbf{m}\mathbf{d}^T\mathbf{m}$$

$$E[(\mathbf{A}\mathbf{x} + \mathbf{a})(\mathbf{B}\mathbf{x} + \mathbf{b})^T(\mathbf{C}\mathbf{x} + \mathbf{c})(\mathbf{D}\mathbf{x} + \mathbf{d})^T] \\ = [\mathbf{A}\Sigma\mathbf{B}^T + (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{B}\mathbf{m} + \mathbf{b})^T][\mathbf{C}\Sigma\mathbf{D}^T + (\mathbf{C}\mathbf{m} + \mathbf{c})(\mathbf{D}\mathbf{m} + \mathbf{d})^T] \\ + [\mathbf{A}\Sigma\mathbf{C}^T + (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{C}\mathbf{m} + \mathbf{c})^T][\mathbf{B}\Sigma\mathbf{D}^T + (\mathbf{B}\mathbf{m} + \mathbf{b})(\mathbf{D}\mathbf{m} + \mathbf{d})^T] \\ + (\mathbf{B}\mathbf{m} + \mathbf{b})^T(\mathbf{C}\mathbf{m} + \mathbf{c})(\mathbf{A}\Sigma\mathbf{D}^T - (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{D}\mathbf{m} + \mathbf{d})^T) \\ + \text{Tr}(\mathbf{B}\Sigma\mathbf{C}^T)[\mathbf{A}\Sigma\mathbf{D}^T + (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{D}\mathbf{m} + \mathbf{d})^T]$$

$$E[(\mathbf{A}\mathbf{x} + \mathbf{a})^T(\mathbf{B}\mathbf{x} + \mathbf{b})(\mathbf{C}\mathbf{x} + \mathbf{c})^T(\mathbf{D}\mathbf{x} + \mathbf{d})] \\ = \text{Tr}[\mathbf{A}\Sigma(\mathbf{C}^T\mathbf{D} + \mathbf{D}^T\mathbf{C})\Sigma\mathbf{B}^T] \\ + [(\mathbf{A}\mathbf{m} + \mathbf{a})^T\mathbf{B} + (\mathbf{B}\mathbf{m} + \mathbf{b})^T\mathbf{A}]\Sigma[\mathbf{C}^T(\mathbf{D}\mathbf{m} + \mathbf{d}) + \mathbf{D}^T(\mathbf{C}\mathbf{m} + \mathbf{c})] \\ + [\text{Tr}(\mathbf{A}\Sigma\mathbf{B}^T) + (\mathbf{A}\mathbf{m} + \mathbf{a})^T(\mathbf{B}\mathbf{m} + \mathbf{b})][\text{Tr}(\mathbf{C}\Sigma\mathbf{D}^T) + (\mathbf{C}\mathbf{m} + \mathbf{c})^T(\mathbf{D}\mathbf{m} + \mathbf{d})]$$

请参见[7]。

5.4.4 高斯混合

对于高斯混合：

$$\mathbf{x} \sim \sum_k \pi_k \mathcal{N}(\mathbf{m}_k, \mathbf{M}_k),$$

这些时刻是加权和：

$$E[\mathbf{x}] = \sum_k \pi_k \mathbf{m}_k, \quad \text{Var}[\mathbf{x}] = \sum_k \pi_k (\mathbf{M}_k + \mathbf{m}_k \mathbf{m}_k^T) - \left(\sum_k \pi_k \mathbf{m}_k \right) \left(\sum_k \pi_k \mathbf{m}_k \right)^T.$$

高阶矩同样通过线性方式组合。

(384)

(385)

关于 m 或 M 的矩的导数可以通过在积分符号下进行微分，并使用高斯情况下的Stein引理来计算。

练习41。

练习42：在矩阵参考手册中查找更多恒等式并尝试证明它们。同时，使用`tensor.dot`验证你的推导过程。

第6章

行列式和逆矩阵

6.1 行列式

用张量符号表示行列式非常方便。

$$\det(A) = \frac{1}{n!} \overline{A \cdots A}$$

其中 $\varepsilon_{i_1, \dots, i_n} = \varepsilon_{i_1, \dots, i_n}$ 表示由下式定义的 n 阶 Levi-Civita 张量。

$$\varepsilon_{i_1, \dots, i_n} = \begin{cases} \text{sign}(\sigma) & \sigma = (i_1, \dots, i_n) \text{ is a permutation} \\ 0 & \text{otherwise.} \end{cases}$$

为了理解这个定义的意义，我们先考虑一下

$$\det(I) = \frac{1}{n!} \overline{1 \cdots 1} = \frac{1}{n!} \sum_{i_1, \dots, i_n, j_1, \dots, j_n} \varepsilon_{i_1, \dots, i_n} \varepsilon_{j_1, \dots, j_n} [i = j] = \frac{1}{n!} \sum_{i_1, \dots, i_n} \varepsilon_{i_1, \dots, i_n}^2 = 1.$$

根据行列式的置换定义，我们通常可以得到：

$$\begin{aligned} \overline{A \cdots A} &= \sum_{i_1, \dots, i_n, j_1, \dots, j_n} \varepsilon_{i_1, \dots, i_n} \varepsilon_{j_1, \dots, j_n} A_{i_1, j_1} \cdots A_{i_n, j_n} \\ &= \sum_{\sigma, \tau} \text{sign}(\sigma) \text{sign}(\tau) A_{\sigma_1, \tau_1} \cdots A_{\sigma_n, \tau_n} \\ &= \sum_{\sigma} \text{sign}(\sigma) \sum_{\tau} \text{sign}(\tau) A_{\sigma_1, \tau_1} \cdots A_{\sigma_n, \tau_n} = \sum_{\sigma} \text{sign}(\sigma)^2 |A| \\ &= n! \det(A). \end{aligned}$$

该定义可推广至凯莱的‘超行列式’....

一个有趣的特点是

$$\begin{array}{c} \dots \\ \hline A \quad \dots \quad A \\ \hline \end{array} = \begin{array}{c} \dots \\ \hline \hline A \quad \dots \quad A \\ \hline \hline \end{array}$$

(18) $\det(A)$ 等于 n 乘以 λ_i

(19) $\det(cA) = c^n \det(A)$ $\begin{array}{c} \dots \\ \hline cA \quad \dots \quad cA \\ \hline \end{array} = c^n \begin{array}{c} \dots \\ \hline A \quad \dots \quad A \\ \hline \end{array}$

(20) 矩阵 A 的行列式等于其转置矩阵 A^T 的行列式。

(21) $\det(AB) = \det(A)\det(B)$ $\begin{array}{c} \dots \\ \hline A \quad \dots \quad A \\ \hline B \quad \dots \quad B \\ \hline \end{array} = \begin{array}{c} \dots \\ \hline \hline A \quad \dots \quad A \\ \hline \hline B \quad \dots \quad B \\ \hline \hline \end{array}$

(22) 行列式 (A^{-1}) 等于 1 除以行列式 (A) $\dots$

(23) 矩阵 A 的转置等于 A 的 n 次幂 $\dots$

(24) $\det(I + uv^T) = 1 + u^T v$ $\dots$

6.2 反向

可能会减少，除非辅因子矩阵有一个很好的表示？

第7章

高级衍生品

7.1 向量范数的导数

7.1.1 二范数

$$\frac{d}{dx} \|x - a\|_2 = \frac{x - a}{\|x - a\|_2} \quad (7.1)$$

$$\frac{d}{dx} \frac{x - a}{\|x - a\|_2} = \frac{I}{\|x - a\|_2} - \frac{(x - a)(x - a)^T}{\|x - a\|_2^3} \quad (7.2)$$

$$\frac{d}{dx} \|x\|_2^2 = \frac{d}{dx} \|x^T x\|_2 = 2x \quad (7.3)$$

7.2 矩阵范数的导数

7.3 结构化矩阵的导数

7.3.1 对称

7.3.2 对角线

7.3.3 托普利茨

7.4 行列式的导数

7.5 一般表格

7.6 线性形式

7.7 方形表单

7.8 来自Stack Exchange

设 $F(t) = |1 + tA|$ ，则 $F'(t) = \text{Tr}(A)$ ， $F''(t) = \text{Tr}(A^2) - \text{Tr}(A)^2$ 。

7.9 逆的导数

7.9.1 跟踪标识

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A}\mathbf{X}^{-1}\mathbf{B}) = -(\mathbf{X}^{-1}\mathbf{B}\mathbf{A}\mathbf{X}^{-1})^T = -\mathbf{X}^{-T}\mathbf{A}^T\mathbf{B}^T\mathbf{X}^{-T}$$

假设B和C是对称的，那么

$$-\frac{\partial}{\partial \mathbf{X}} \text{Tr}[(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}\mathbf{A}] = -(\mathbf{C}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1})(\mathbf{A} + \mathbf{A}^T)(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}[(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{B}\mathbf{X})] = -2\mathbf{C}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{B}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}$$

$$\begin{aligned} \frac{\partial}{\partial \mathbf{X}} \text{Tr}[(\mathbf{A} + \mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{B}\mathbf{X})] &= -2\mathbf{B}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1} \\ &\quad - 2\mathbf{C}\mathbf{X}(\mathbf{A} + \mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{B}\mathbf{X}(\mathbf{A} + \mathbf{X}^T\mathbf{C}\mathbf{X})^{-1} \\ &\quad + 2\mathbf{B}\mathbf{X}(\mathbf{A} + \mathbf{X}^T\mathbf{C}\mathbf{X})^{-1} \end{aligned}$$

7.10 特征值的导数

7.11 练习

练习43. 求导数

$$f(x, \Sigma, \mu) = \frac{1}{\sqrt{(2\pi)^k |\Sigma|}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right)$$

关于 Σ 。

第8章

特殊矩阵

8.0.1 块矩阵

像舒尔补集这样的东西很有趣。但是，我们能用量图说些什么有用的话吗？

8.0.2 离散傅立叶变换矩阵

我认为FFT可以用图表很好地描述

我们先从哈达玛矩阵开始： $H_n = [1 \ 1 \dots 1 \ 1]^{n \times n}$ 。这不过是一堆矩阵堆叠在一起，有点单调乏味。

FFT呢？这需要更多吗？

8.0.3 快速克罗内克乘法

假设我们要计算 $(A_1 \otimes A_2 \otimes \dots \otimes A_n) x$ ，其中 A_i 是一个 $a_i \times a_i$ 的矩阵，而 $x \in \mathbb{R}^{a_1 \times a_2 \times \dots \times a_n}$ 。如果先计算Kronecker积，再进行矩阵-向量乘法，这将需要 $(a_1 \times \dots \times a_n)^2$ 的时间。

相反，我们可以将 x 重塑为一个 $a_1 \times \dots \times a_n$ 的张量，并执行乘法运算。

$$\begin{array}{c} \overset{a_1}{\text{---}} A_1 \overset{a_1}{\text{---}} \\ \overset{a_2}{\text{---}} A_2 \text{---} \\ \vdots \\ \text{---} \end{array} \begin{array}{c} \diagdown \\ \text{---} \\ \diagup \end{array} X$$

通过逐一收缩 A_i 边来实现，这需要时间。

$$a_{21} (a_2 \dots a_n) + a_{22} (a_1 a_3 \dots a_n) + \dots + a_{2n} (a_1 \dots a_{n-1}) = (a_1 + \dots + a_n) (a_1 \dots a_n)$$
，这一公式是许多快速算法的基础，我们将在后续内容中详细探讨。

哈达玛

哈达玛矩阵定义为 $H_{2n} = H_2 \otimes H_{n-1}$ ，其中 $H_2 = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$ 。例如

$$H_4 = H_2 \otimes H_2 = \begin{bmatrix} H_2 & H_2 \\ H_2 & -H_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix}.$$

这给出了一个非常简单的张量图表示：

$$H_{2^n} = \begin{array}{c} \text{---} \\ \text{---} \\ \text{---} \\ \text{---} \\ \text{---} \end{array} \begin{array}{c} H_2 \\ \vdots \\ H_2 \end{array} \begin{array}{c} \text{---} \\ \text{---} \\ \text{---} \\ \text{---} \\ \text{---} \end{array} .$$

快速哈达玛变换 (FHT) 变换通常通过递归方式描述：

$$H_{2^n}x = \begin{bmatrix} H_{2^{n-1}} & H_{2^{n-1}} \\ H_{2^{n-1}} & -H_{2^{n-1}} \end{bmatrix} \begin{bmatrix} x^{(1)} \\ x^{(2)} \end{bmatrix},$$

其中 $[xx(12)]$ 代表 x 的前半部分和后半部分。由于矩阵乘法存在冗余（仅依赖于 $H_{2n-1x(1)}$ 和 $H_{2n-1x(2)}$ ），该算法能在 $O(N \log N)$ 的时间复杂度内完成 $H_N x$ 的计算。

或者，我们也可以直接采用上述提到的一般性结论，即对于所有 i ， a_i 均等于 2。此时，“快速克罗内克乘法”方法所需时间可表示为 $(a_1 a_2 \cdots a_n) (a_1 + a_2 + \cdots + a_n)$ ，其复杂度为 $2^n \log_2 n$ 。

热欧姆


离散傅里叶矩阵由公式 $(F_N)_{ij} = e^{-j2\pi i/N}$ 定义，其中 $e^{-j2\pi i/N}$ 表示 e 的 $-j2\pi i/N$ 次方。

$$F_N = \begin{bmatrix} 1 & 1 & 1 & 1 & \dots & 1 \\ 1 & \omega & \omega^2 & \omega^3 & \dots & \omega^{N-1} \\ 1 & \omega^2 & \omega^4 & \omega^6 & \dots & \omega^{2(N-1)} \\ 1 & \omega^3 & \omega^6 & \omega^9 & \dots & \omega^{3(N-1)} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \omega^{N-1} & \omega^{2(N-1)} & \omega^{3(N-1)} & \dots & \omega^{(N-1)(N-1)} \end{bmatrix}.$$

$$= \left\{ \exp 2 \pi i \frac{\text{arange}(N)}{N} \right\}$$

任务：展示如何使用函数符号表示矩阵。

Good-Thomas快速傅立叶变换（FFT）采用基于中国剩余定理的分解方法：




其中 $N = p_1^{i_1} p_2^{i_2} \cdots p_n^{i_n}$ 是 N 的质因数分解，而 P_1 和 P_2 是某些置换矩阵。

使用快速克罗内克乘法，该算法的计算时间为 $(p_1^{i_1} + \cdots + p_n^{i_n})^N$ 次。通过在 x 的末尾添加零，我们可以将 N 增加一个常数因子，从而得到一个由 n 个 $O(\log(N)/\log \log(N))$ 的质数组成的字符串，这些质数的总和为 $\sim n^2/\log n = O(\log(N)^2)$ 。因此，整个算法的时间复杂度为 $O(N \log(N)^2)$ 。接下来，我们将探讨如何将这一时间复杂度降低到 $O(N \log N)$ 。

经典的Cooley-Tukey FFT算法使用递归：

$$F_N = \begin{bmatrix} I & I \\ I & -I \end{bmatrix} \begin{bmatrix} I & 0 \\ 0 & D_{N/2} \end{bmatrix} \begin{bmatrix} F_{N/2} & 0 \\ 0 & F_{N/2} \end{bmatrix} \begin{bmatrix} \text{even-odd} \\ \text{permutation} \end{bmatrix},$$

其中 $D_N = [1, w_N, w_N^2, \dots]$ 。奇偶置换将所有偶数值移至首位。若将 $12n$ 重塑为 $12 \cdot \cdots 12$ ，则该置换即为 PN 。在pytorch中，可以使用 $x.\text{permute}([3,0,1,2])$ 。另外需要注意的是， $\begin{bmatrix} I & I \\ I & -I \end{bmatrix} = H_2 I$ ，以及 $\begin{bmatrix} F_{N/2} & 0 \\ 0 & F_{N/2} \end{bmatrix} = I \otimes F_{N/2}$ 。因此，我们可以在张量图符号中表示为：




由于可以在线性时间内与置换矩阵和对角矩阵相乘，因此 $O(n \log n)$ 时间复杂度与Hadamard矩阵的论证相同。

请注意，由于矩阵是对称的，因此存在多种对称性，例如通过水平翻转（即转置）实现对称性。或者将置换向左侧移动。


我们不需要把矩阵分成两半，我们也可以把它分成三分之一，四分之一等等。

使用这个通用的Cooley-Tukey算法，我们得到如下图：




其中 n_0, n_1, n_2 和 n_3 的总和为 N 。这里，我们用“广义”傅里叶矩阵 $F(a, b)$ 替换了 D_N 矩阵，该矩阵定义为 $F_j(a, k, b) = e^{-2\pi i j k / (ab)}$ ，并根据需要进行重新排列。在简单的情况下，当我们把数据分为大约两部分，即 $n_1 = n_2 = \sqrt{N}$ 时，这种方法也被称为“四步快速傅里叶变换”或Bailey的快速傅里叶变换算法。

我们可以通过应用性质 $Fa, bc = Fa, b^*F1a, /cb$ 来进一步简化图表：



在每次将数据分成两部分的简单情况下，这被称为“量子FFT”算法。
我们在上面隐藏了一些内容，即矩阵需要除以不同的N值。请注意，这个图可能与你之前见过的一些FFT图表有所不同。
它们通常看起来像这样：



并且有2的n次方行。张量图仅包含n行（或log2 N）。多维傅里叶变换

这只是沿着每个轴进行傅里叶变换。

8.0.4 厄米特矩阵和斜厄米特矩阵

复杂。跳过

8.0.5 幂等矩阵

跳

8.0.6 正交矩阵

跳

8.0.7 正定矩阵和半定矩阵

跳

8.0.8 单条目矩阵, The

描述矩阵J。所有这些都图表来说明。

8.0.9 对称、斜对称/反对称

可以在这里引入彭罗斯的对称张量吗？

8.0.10 Toeplitz矩阵

可以在这里讨论卷积张量...

8.0.11 单位、置换和移位

没那么有趣...

8.0.12 范德蒙矩阵

这有好的描述吗？《烹饪书》中没有给出很多属性。

第9章

分解

9.1 高阶奇异值分解

假设我们有一个 n 阶张量 A 。我们将 A 沿着每个维度展开，即把第 i 个边向左拉平，其余部分向右展平。接着，我们计算SVD（奇异值分解），得到 USV 。这里 U 是一个方阵，我们保留它。然后，我们将 A 的第 i 个边与 U^T （也就是 U 的逆）相乘。这样，我们不仅得到了一个“核心”张量，还得到了一系列 U 张量。如果需要更紧凑的SVD，可以将每个 U 设为低秩，就像普通的SVD一样。此外，还有一种“交错计算”的方法，即在展开过程中逐步将 U^T 乘到 A 上。

对于阶数为3的张量，这种方法被称为“Tucker分解”。

如果‘核心矩阵’是对角线形式，这被称为张量秩分解。如果我们擅长此法，就可以利用它对 I^3 进行因式分解，从而开发出更高效的矩阵乘法算法。然而，张量秩分解问题是NP难问题。

我猜HOSVD在对核心张量进行对角化后，可以给出一个秩分解。不过这个方法效率不高。

9.2 等级分解

9.2.1 边框等级

张量的边界秩是指与之最接近的最小秩。待补充：边界秩远小于秩的例子。

9.3 快速矩阵乘法

斯特拉森定义了三个形状为 $7 \times 2 \times 2$ 的张量：

$$S_A = \begin{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, & \begin{bmatrix} 0 & 0 \\ 1 & 1 \end{bmatrix}, & \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, & \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}, & \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, & \begin{bmatrix} -1 & 0 \\ 1 & 0 \end{bmatrix}, & \begin{bmatrix} 0 & 1 \\ 0 & -1 \end{bmatrix} \end{bmatrix}$$
$$S_B = \begin{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, & \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, & \begin{bmatrix} 0 & 1 \\ 0 & -1 \end{bmatrix}, & \begin{bmatrix} -1 & 0 \\ 1 & 0 \end{bmatrix}, & \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}, & \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, & \begin{bmatrix} 0 & 0 \\ 1 & 1 \end{bmatrix} \end{bmatrix}$$

$$W = \left[\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \begin{bmatrix} 0 & 1 \\ 0 & -1 \end{bmatrix}, \begin{bmatrix} 0 & 0 \\ 1 & 1 \end{bmatrix}, \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}, \begin{bmatrix} -1 & 0 \\ 1 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \right]$$

这些张量具有一个显著的特性，即它们可以分解为 $I^2 \otimes I^2 \otimes I^2$ 的形式。

为了比常规的 n^3 时间更快地乘以两个矩阵 A 和 B，我们将其重塑为块矩阵，形状 $(2, \frac{n}{2}, 2, \frac{n}{2})$ ，并使用 Strassen 张量：

按正确的顺序收缩边缘，仅使用 $7/8 n^3 + O(n^2)$ 操作。

如果我们改为 $(2, 2, \dots, 2)$ ，

通过在每个轴上应用斯特拉斯张量，可以将工作量减少 $(7/8) \log_2(n)$ ，从而实现矩阵乘法的时间复杂度为 $n^3 + \log_2(7/8) = n^{2.80735}$ 。

收缩双边SA-A和SB-B的时间复杂度均为 $O(n^2)$ 。

接下来需要验证这是否真的比简单的矩阵乘法更快：收缩SA—A需要 $7 \cdot 22 (n/2)^2$ 次操作，同样地，收缩SB—B也是如此。接下来，收缩SAA—SBB需要 $7 (n/2)^3$ 的时间。最后，收缩带有W的边需要 $22 \cdot 7 (n/2)^2$ 的时间。关键在于立方项 $7/8n^3$ ，如果采用递归方法处理，这将导致经典的 $O(n \log^2 7)$ 算法。

注：‘与W的边’是什么意思？我认为我们需要/想要立即收缩包含W的超边吗？

其他的

如果我们用 (n, m) 和 (m, p) 形状的块来表示A和B，就可以通过因式分解得到 $ln?lm?lp$ ，并采用与上述Strassen $(2, 2, 2)$ 张量相同的方法来实现矩阵乘法算法。许多研究探讨了这一问题，最终由Josh Alman等人开发出了最佳算法。例如，Deep Mind发现了一个47阶的 $l3?l4?l5$ 因式分解。

或许更有趣的例子是 $(4, 4, 4)$ 张量，他们发现了一个47阶的因子分解。通过取斯特拉斯的值并将其加倍，可以轻松创建一个49阶的张量。这会是一个不错的选择吗？或许太杂乱了？其实，他们的47级构造仅适用于“模块化”情况。因此， $(3, 4, 5)$ 才是通用的。

第10章

机器学习应用

10.1 最小二乘法

10.2 交叉熵损失的Hessian矩阵

10.3 卷积神经网络

10.4 变压器/注意

10.5 Tensor草图

10.6 强化学习

在考虑不完全信息博弈时，我们尝试用低秩张量来近似每个玩家的策略。具体来说，可以使用张量草图来近似张量，即随机选择向量的外积，并乘以导数。这种方法应该很快。

..

第十一章

矩阵算法

11.1 张量收缩顺序

在前几章中，我们构建了许多张量网络。虽然这些理论知识对于某些应用来说已经足够，但在计算领域，如量子电路模拟，实际需要计算张量网络背后的张量。这通过所谓的张量收缩来实现。为了更好地理解这一点，考虑以下的2-张量图，其中我们对两个张量A和B进行了收缩：

$$\begin{array}{c} \begin{array}{|c|} \hline 2 \\ \hline \end{array} \quad \begin{array}{|c|} \hline 4 \\ \hline \end{array} \\ \hline A \quad B \end{array} \xrightarrow{\text{Contraction}} \begin{array}{|c|} \hline 2 \\ \hline \end{array} \quad \begin{array}{|c|} \hline 2 \\ \hline \end{array} \\ \hline A' \end{array}$$

请注意，我们还列出了各个维度的大小，即A是一个 $2 \times 2 \times 4$ 张量，而B是一个 4×2 矩阵。收缩成本定义为在收缩过程中执行的浮点运算次数；按照惯例，这指的是标量乘法的次数。在我们的例子中，收缩成本为 $2 \times 2 \times 4 \times 2 = 32$ ，即我们直接将维度大小相乘。

前面的例子规模较小。然而，在实际应用中，张量网络通常包含数百个张量。这些张量同样需要被收缩成一个单一的张量。现在进入有趣的部分：执行这些收缩操作的顺序对计算时间有着巨大的影响。为了对此有一个直观的认识，考虑一个扩展的3-张量图示的例子：

$$\begin{array}{c} \begin{array}{|c|} \hline 2 \\ \hline \end{array} \quad \begin{array}{|c|} \hline 2 \\ \hline \end{array} \quad \begin{array}{|c|} \hline 2 \\ \hline \end{array} \quad \begin{array}{|c|} \hline 2 \\ \hline \end{array} \quad \begin{array}{|c|} \hline 4 \\ \hline \end{array} \quad \begin{array}{|c|} \hline 1 \\ \hline \end{array} \quad \begin{array}{|c|} \hline 2 \\ \hline \end{array} \quad A \quad B \quad C \end{array}$$

如果我们先将A与B进行收缩（然后将得到的张量与C进行收缩），那么总乘法次数为 $22 \times 4 \times 2 + 23 \times 1 \times 22 = 32 + 32 = 64$ 次。而如果一开始就让B和C进行收缩，总乘法次数则为 $23 \times 1 \times 22 + 22 \times 4 \times 23 = 32 + 128 = 160$ 次。因此，第一种方法在计算上更为高效。

因此很自然地会问：我们总能找到最佳的收缩顺序吗？

¹这假设了操作的简单实现，即对维度进行嵌套循环。

11.1.1 算法

我们总结了众所周知的结果和框架，以找到好的收缩顺序。

最佳算法

确实，对于任意张量网络形状，找到最优的收缩顺序非常困难；更准确地说，这是一个NP难问题[3]。有一个著名的精确算法，可以在 $O(3^n)$ 时间内运行[17]，其中 n 代表网络中的张量数量。该算法能够根据总收缩成本找到最优的收缩顺序。如果目标是减少最大中间张量的大小，即优化执行过程中使用的内存，那么这一过程可以在 $O(2^{n^3})$ 时间内完成[22]。

好消息是，对于某些特定形状的张量网络，确实存在高效的算法。一个典型的例子是矩阵链问题（[4]）的动态规划解决方案，这正是我们面临的问题，但仅限于矩阵。虽然朴素算法的时间复杂度为 $O(n^3)$ ，但可以通过优化实现为 $O(n^2)$ 时间[26]（甚至可以达到 $O(n \log n)$ 时间[11,12]）。此外，树形张量网络（[25,23]）也存在多项式时间算法。

另一种优化收缩顺序的显著方法是通过张量网络[15,5,19]的线图表示进行树分解。具体来说，这种方法可以生成一个收缩顺序，其中的最大中间张量秩等于树分解的树宽。简单来说，树宽衡量的是图的树状结构。然而，这并不能直接解决我们的问题，因为找到最小树宽的树分解本身就是一个难题[14]。两个著名的框架用于寻找良好的树分解，分别是QuickBB [6]和FlowCutter [24,9]。

最佳努力算法

然而，当我们需要对任意网络形状进行收缩时，最好的方法是采用启发式或近似的方法。两个著名的框架是opt_einsum [20]和cotengra [7]，它们旨在优化任意einsum的收缩顺序（也称为“收缩路径”）。对于那些最优算法运行速度过慢的张量网络，opt_einsum采用了一种特定的贪婪算法，而cotengra则结合了超图划分[18]和贝叶斯优化方法，后者后来得到了进一步的改进[21]。其他从数据库查询优化中借鉴的算法已在netzwerk [23]中实现。另一种方法是通过强化学习[16]来学习最佳收缩顺序。

当然，上述启发式方法并不具备最优性保证。存在一种 $(1+\epsilon)$ 近似度、 $O^*(2n/\epsilon)$ 时间复杂度的算法，该算法能够最小化中间张量大小[22]的总和。

值得一提的是einsum [2]的SQL视图：它允许在任何数据库引擎上执行整个张量网络的收缩。实际上，对于某些einsum类，使用最先进的数据库引擎（如Hyper[13]）进行收缩操作，比使用实际的numpy数组实现要快得多。

第十二章

张量梯度

实施细节

12.1 同构

其实有一个“张量同构”的概念，但它基本上和图同构是一样的。

我们需要理解代码的许多不同部分中的同构。

12.1.1 在产品中

取消/合并等量的产品部分。这实际上非常困难，因为需要收集构成同构子图的节点子集。目前我们通过仅考虑产品的独立组件来解决这个问题。




图12.1：将产品等量混合。基本问题如下：

1. 给定一个多重图G，其中包含节点V和边E。
2. 节点和边都已标记。
3. 你需要找到V的两个不相交子集V?和V?，使得由V?和V?分别诱导出的子图G?和G?是同构的。此外，在这种同构关系下，G?和G?中的节点和边的标签必须相同。

这个问题可能属于NP难问题，但或许仍能找到一种比尝试所有子集更快的算法。特别是，我们可以修改VF2算法，该算法通过迭代尝试匹配G1和G2中的节点。NetworkX库中已有一个GraphMatcher，用于搜索同构子图。这个工具可能可以扩展到我们的问题上……但说实话，我不确定我们是否真的需要以最广泛的方式解决这个问题，因为这有点像对图进行因式分解。我们不进行因式分解，就像我们不进行逆分布一样。

无论哪种情况，很明显我们需要能够比较节点和边的同构性。

此外，同构规范化在产品中的基本用例仅仅是计算其组成部分的规范产品本身。我们在这里的方法之一是将边缘转换为节点，这样就可以对它们进行着色。

12.1.2 总计

在判断A+B是否等于2A时，需要检查A和B是否同构。但同时，还需考虑当前边的重命名情况。因此，不能简单地将A + AT转换为2A。

它在我的代码中实际的工作方式是

```

1 对于键_函数 (t: 张量),
2      将张量边对齐，使其具有相同的阶数，并以Sum的阶数作为参考。
3      规范= [ t. canonical_edge_names [ t. edges.index (e) ]对于e属于自身边的元素]返回哈希 ( (
4          t. canon , ) + tuple (规范) )
5
6  ws_tensors是一个张量字典，其键为_fn，默认值为int。
7  对于w和t，它们属于zip (权重，张量)：
8      ws_矩阵[ t ] += w
9  ws_tensors = [ (w, t) 对于t和w属于ws_tensors的元素 ( ) ) ]

```

这表示我使用的是哈希，即张量的规范形式加上边的规范形式，按照边在求和中的顺序排列。这些基本上就是轨道，意味着如果求和后的张量具有对称性，我们可以‘翻转’它，使各加项同构。

在“计算规范”方法中，我们或多或少做同样的事情，但我们还包括权重。

```

1 定义_compute_canonical (self)：
2      哈希= []
3      对于e和self的边：
4          规范= [ t. canonical_edge_names [ t. edges.index (e) ]对于t属于self中的元素。
5              张量]
6          哈希。追加 (哈希 ( ( “总和 ”, ) +元组 (排序 (自变量的权重与标准值的组合) ) ) )

```

```

6 基础=哈希( ("总和", len(自变量的张量)), 哈希=[哈
7 希(基础, h) 对于h属于哈希]返回基础, 哈希
8

```

未来，我们计划使用对称群。求和的对称群是什么？它是各加数对称群乘积的对角线。如何找到这个群的生成元？或许我们可以先构建一个联合图，然后找出该图的自同构。

或者，我们也可以使用sympy。目前尚不清楚这个问题是否能在多项式时间内解决。据我所知，Babai证明了这个问题是准多项式的，但没有提出实用的算法。顺便提一下，Eugene Luks证明了子群的交集、元素的中心化子以及 $\{1, \dots, n\}$ 的子集的稳定子的问题在多项式时间内是等价的。

实际上，制作图表并使用nauty确实是个好主意，因为它能够检测到 $A + A^T$ 的对称性。仅仅取各加项的自同构群的交集是无法发现这一点的。

另一个选择是将这个数转换成一个函数...但是，不，这很奇怪。这将要求我支持具有任意数量输入的功能，而目前的情况并非如此。

12.1.3 正在评估

在评估一个张量时，我们可以通过查看该张量的图来判断它是否与之前评估过的张量同构。这里的情况不需要标准形式，但使用近似哈希加上vf2也是可以的。此外，我们不关心边的重命名，因为可以在返回张量前直接重命名这些边。例如，如果我们已经评估了 A ，就可以利用这一点轻松地得到 A^T 。

12.1.4 在变量中

在变量中，我们在哈希中包含变量的名称。基本上，我们假设同名变量指的是相同的数据。

```

1  base = 哈希( ("变量", self.name) )
2  返回base, [对于e属于self的原始边, 计算 (base, e) 的哈希值]

```

对于原始规范的边名，我们使用重命名前的边名。这意味着，在 A^T 的情况下，它将与 A 具有相同的哈希值。但由于进行了重命名，总和中的 t 索引调用会反转这些边。

我们可以想象变量取自同构群作为参数，这将允许我们定义具有不同对称性的变量。例如对称矩阵 A ，其中 $A + A^T$ 实际上是 $2A$ 。

12.1.5 在常量中

在计算常量的规范形式时，例如Zero或Copy，我们并不关心边的名称。我想这是因为我们使用的常量都是最大程度对称的？目前我们包含了常量标签，这是该变量的哈希值，如果有的话。

12.1.6 在函数中

一个问题在于，虽然原始名称通常是函数定义的一部分，但通过微分添加的新边通常基于上下文自动生成，因此它们实际上不应成为规范形式的一部分。

与Sum不同的是，我们在这里不对规范进行排序，因为输入的顺序很重要。

或许应该允许函数转换对称群？例如，如果有一个函数接收一个对称矩阵并返回另一个对称矩阵，我们应当能够利用输入的对称群来简化输出。

12.1.7 在衍生品领域

我们所做的就是对张量和wrt进行哈希处理，然后为导数添加新的边。

12.1.8 其他的

对于某些张量，可能存在不是等价关系的边缘维度关系。例如，一个展平张量的“输出”边缘维度等于其“输入”边缘维度的乘积。

在之前的版本中，我让每个张量都注册了一个“回调”函数。每当一个边维度“变得可用”时，张量就会有可能会生成新的边维度。然而，这需要为每个张量实现更多的工作，并且不需要任何现有的张量。

12.2 重命名

这是代码的一个重要部分。

12.3 评价

评估的一个重要环节是确定每个边的维度。为此，我使用了一个名为edge_equivalences的函数来构建张量的完整图，该函数接收一个元组列表（（t1, e1），（t2, e2）），表示张量t1中的边e1与张量t2中的边e2相等。需要注意的是，同一边的名字可能在图中多次出现，因此我们需要同时跟踪这些张量。

对于变量，由于用户以变量的形式给出边的维度，因此需要跟踪重命名的边名称：

```
1 对于zip中的e1和e2（来自self. original_edges和self. edges）：
2      产率（自，e1），（自，e2）
```

对于常量，可能基于该常量所衍生的张量存在一些等价关系。

```
1 定义edge_equivalences（自身）：
2     如果self. link不为NULL：
3         从self. link. edges中的每个边e调用edge_equivalen-
4         ces（）函数，以获取其收益：
```

```

5         如果在self中存在边：
6             产率 (自, e) , (自.链接, e)

```

对于拷贝张量，所有内容都等同：

```

1 定义edge_equivalences (self) :
2     从超边 (super () ) 中, 对e在自身边[1:]中的边等
3     价关系 (edge_equivalences () ) 进行求取：
4     (自, 自的边[0]) , (自, e)

```

对于函数，我们无法真正了解函数本身的边界 (self.edges_out)，但至少可以对广播的边界做出一些说明。

```

1 for t, *inner_edges in self.inputs:
2     从 t 中的 边 e 的 边 等 价 关 系 (edge_
3     equivalences () ) 中提取：
4     如果e不在内边中：
5         产量 (吨, e) , (自身, e)

```

我们或许也可以认为，具有相同名称的输入边是等价的？对于产品而言，我们会检查每条边 (t?, e, t?)，并生成 (t?, e)，(t?, e)。然而对于对于自由边 (t, e)，我们将其与自身 (t, e)、(self, e) 进行匹配。

```

1 定义edge_equivalences (自身) :
2     pairs是一个默认值为列表的字典。
3     对于t属于self的张量：
4         从 t 中的 边 e 的 边 等 价 关 系 (t.edge_
5         equivalences) 中提取：
6         对于每个元素e和t, 使用
7         append (t) 方法将它们添加到列表
8         中。items () 函数：
9         if len(ts) == 1:
10            当满足以下条件时, 返回 (self,
11            e) ;若不满足, 则返回 (ts [0], e) 。
12            t1, t2 = ts
13            产量 (t?, e) , (t?, e)

```

同样，对于总和，一切都与我们自己相匹配：

```

1 定义edge_equivalences (自身) :
2     对于t属于self的张量：
3         从 t 中的 边 e 的 边 等 价 关 系 (t.edge_
4         equivalences) 中提取：
5         产量 (吨, e) , (自身, e)

```

最后，我们使用BFS将边的维度从变量（由用户给出）传播到图的其余部分。

为什么非变量需要知道边的维度？主要是因为超边的复制张量，我们必须构建这些张量。如果我们能更高效地计算超边而不使用复制，是否可以省去这一过程？有时也会出现‘分离’的复制...

此外，另一个替代方案是实际构建完整的图。我最初认为这不可能实现，因为和值实际上并不是真正的图。但或许通过采用nauty的新方法，我们真的可以做到这一点。

12.3.1 乘积

我们只需评估乘积中的张量，并将它们提供给einsum。

12.4 简化规则

有很多这样的。

大多数情况下，我们可以在一次深度优先遍历中完成所有操作，但有时需要进行多次遍历。这可以通过全简化方法实现，该方法会反复调用简化过程，直到不再发生变化为止。

参考文献

- [1] John Aldrich.《数学词汇的起源：拉丁语、希腊语和阿拉伯语词根的全面词典》。美国数学协会，2010年。
- [2] 马克·布勒赫、朱利安·克劳斯、克里斯托夫·施陶特、索伦·劳厄、维克托·莱斯和约阿希姆·吉森。《SQL中的高效便携式爱因斯坦求和方法》。收录于《ACM管理数据学报》，第1卷第2期，第121页，2023年。
- [3] Lam Chi-Chung、P Sadayappan和Rephael Wenger.《关于优化一类具有归约的多维循环以实现并行执行》。《并行处理通讯》，7（02）：157–168,1997.
- [4] Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest 和 Clifford Stein。
《算法导论》第三版，麻省理工学院出版社，2009年。
- [5] 杰弗里·M·杜德克、莱昂纳多·杜埃尼亚斯-奥索里奥和莫谢·Y·瓦尔迪。通过图分解实现大张量网络的有效收缩以进行加权模型计数。arXiv预印本arXiv：1908.04381,2019年。
- [6] Vibhav Gogate和Rina Dechter.一种用于树宽的完整任意时间算法。收录于David Maxwell Chickering和Joseph Y.的著作中。哈尔彭等编，《UAI 2004》，第20届人工智能不确定性会议论文集，加拿大班夫，2004年7月7日至11日，第201-208页。AUAI出版社，2004年。
- [7] 约翰尼·格雷和斯特凡诺斯·库尔蒂斯。超优化张量网络收缩。
量子，5：410,2021。
- [8] greg (<https://math.stackexchange.com/users/357854/greg>) . 证明 $\text{vec}(\text{adiag}(b)c) = (\text{ct?1a} \begin{bmatrix} 8 \end{bmatrix} (1c?a)) b$ 。Mathematics Stack Exchange。URL：
<https://math.stackexchange.com/q/2993406>（版本：2018-11-11）。
- [9] 迈克尔·哈曼和本·斯特拉瑟。帕累托优化下的图二分法。实验算法学报（JEA），23：1–34,2018.
- [10] William Rowan Hamilton，《四元数讲义》，Hodges and Smith出版社，1853年。
- [11] H.T.HU和M. T. Shing.矩阵链乘法的计算方法。第一部分。SIAM期刊。
Comput., 11(2):362–373, 1982.
- [12] H.T.HU和M. T. Shing.矩阵链乘法的计算方法。第二部分。SIAM
J. Comput., 13(2):228–251, 1984.

- [13] 阿尔冯斯·肯珀和托马斯·诺伊曼。《Hyper：基于虚拟内存快照的混合OLTP与OLAP主内存数据库系统》。收录于2011年IEEE第27届国际数据工程会议论文集，第195-206页。IEEE，2011年。
- [14] 图卡·科霍宁。一种针对树宽的单指数时间2近似算法。《SIAM计算杂志》，(0)：FOCS21-174, 2023。
- [15] 伊戈尔·L·马尔科夫和石耀云。通过收缩张量网络模拟量子计算。《SIAM计算杂志》，38(3)：963-981, 2008。
- [16] 埃利·梅罗姆、哈加伊·马龙、谢·曼诺尔和加尔·切奇克。利用强化学习优化张量网络收缩。收录于《国际机器学习会议》第15278-15292页，PMLR，2022年。
- [17] 罗伯特·N·C·普费弗、朱托·海格曼和弗兰克·维尔斯特雷特。张量网络最优收缩序列的快速识别方法。《物理评论E》，90：033315, 2014年。
- [18] Sebastian Schlag、Vitali Henne、Tobias Heuer、Henning Meyerhenke、Peter Sanders和Christian Schulz。通过n级递归二分法实现K-路超图划分。收录于《第十八届算法工程与实验研讨会（ALENEX）论文集》2016年，第53至67页。SIAM，2016。
- [19] 罗曼·舒特斯基、丹尼尔·利科夫和伊万·奥塞莱德茨。量子电路模拟的自适应算法。《物理评论A》，101：042335, 2020年4月。
- [20] 丹尼尔·G·A·史密斯和约翰尼·格雷。opt_einsum——一个用于优化einsum类表达式收缩顺序的Python包。《开源软件杂志》，第3卷第26期：753页，2018年。
- [21] 克里斯托夫·施陶特、马克·布勒赫、朱利安·克劳斯、法林·利普曼和约阿希姆·吉森。
改进张量网络收缩阶的优化策略。收录于Leo Liberti主编的《第22届国际实验算法研讨会（SEA 2024）》论文集，该会议于2024年7月23日至26日在奥地利维也纳举行，属于LIPIcs系列第301卷，第27：1至27：19页。该论文由达格斯图尔莱布尼茨计算机科学中心于2024年发表。
- [22] 米哈伊尔·斯托扬和安德烈亚斯·基普夫。《Dpconv：超多项式级联的更快连接排序》，2024年。
- [23] 米哈伊尔·斯托扬、理查德·M·米尔布拉特和克里斯蒂安·B·门德尔。关于树张量网络的最优线性收缩阶数及其扩展。《SIAM科学计算杂志》，46(5)：B647-B668, 2024年。
- [24] Ben Strasser。使用流切割器计算树分解：PACE 2017 提交。CoRR, abs/1709.08949, 2017。
- [25] 赵建宇、李玲、邓磊、文长云、谢元和李国琦。从树结构构建张量网络最优收缩序列的多项式算法。物理评论E，100：043309, 2019。
- [26] F. Frances Yao。《利用四边形不等式实现的高效动态规划》。收录于Raymond E. Miller、Seymour Ginsburg、Walter A. Burkhard和Richard J. Lipton编辑的《第12届ACM计算理论年会论文集》，1980年4月28日至30日，美国加利福尼亚州洛杉矶，第429至435页。ACM出版社，1980年。

第十三章

附录

包含一些证明，例如方程524或571的证明。这些证明相当长，可以用来与图表证明进行对比。